



Presentación de la asignatura

Machine Learning TLY1101

Contenido

01


Presentación de la
asignatura

02

Introducción

03

¿Qué se necesita
para el curso?





Presentación de la asignatura



Posición en la Malla – TLY1101



1° SEMESTRE	2° SEMESTRE	3° SEMESTRE	4° SEMESTRE	5° SEMESTRE	6° SEMESTRE	7° SEMESTRE	8° SEMESTRE
FPY1101 FUNDAMENTOS DE PROGRAMACIÓN	DSY1102 DESARROLLO ORIENTADO A OBJETOS	DSY1103 DESARROLLO FULL STACK I	DSY1104 DESARROLLO FULL STACK II	ITY1101 GESTIÓN DE DATOS PARA IA	ITY1102 ARQUITECTURA DE SISTEMAS IA	TLY1103 PROGRAMACIÓN EN LENGUAJE NATURAL Y REDES NEURONALES GRÁFICAS	IAY4610 TALLER APLICADO DE IA
DSY1101 INTRODUCCIÓN A CLOUD COMPUTING	BDY1101 BASE DE DATOS APLICADA I	BDY1102 BASE DE DATOS APLICADA II	DSY1105 DESARROLLO DE APLICACIONES MÓVILES	IAY1101 IA ÉTICA Y SOCIAL	TLY1101 MACHINE LEARNING	TLY1104 TÉCNICAS AVANZADAS DE MACHINE LEARNING II	TTY1103 TALLER DE TECNOLOGÍAS DE VANGUARDIA
BIY1101 BASES DE INNOVACIÓN	RQY1101 INGENIERÍA DE REQUISITOS	RQY1102 INGENIERÍA DE SOFTWARE	BDY1103 TALLER DE BASE DE DATOS		TLY1102 TÉCNICAS AVANZADAS DE MACHINE LEARNING I	TLY1105 COMPUTER VISION CON DEEP LEARNING	PPY4610 PRÁCTICA PROFESIONAL
						MOY1102 MLOPS	
MAT1111 NIVELACIÓN MATEMÁTICA	MAT2121 MATEMÁTICA APLICADA	INU4100 INGLÉS ELEMENTAL II	MAT4141 ESTADÍSTICA DESCRIPTIVA	MAT4152 INFERENCIA ESTADÍSTICA	MAT6130 ÁLGEBRA LINEAL		
PLC1110 HABILIDADES DE COMUNICACIÓN	INU3100 INGLÉS ELEMENTAL I		INU5100 INGLÉS INTERMEDIO I	MAT3131 HERRAMIENTAS DE CÁLCULO DIFERENCIAL			
	FCE1100 FUNDAMENTOS DE ANTROPOLOGÍA	1 FORMACIÓN CRISTIANA					
			EAY4470 ÉTICA PARA EL TRABAJO			EAY4615 ÉTICA PROFESIONAL	

Resultados de aprendizaje e Indicadores de Logro

RESULTADO DE APRENDIZAJE	INDICADORES DE LOGRO
RA1 Implementa estrategias y técnicas de preprocesamiento de datos, en el marco de diseño de soluciones de Machine Learning que promuevan un tratamiento responsable de la información.	IL1.1 Aplica técnicas de escalamiento y codificación de variables considerando su tipo, en el contexto de la preparación de conjuntos de datos para modelos de Machine Learning.
	IL1.2 Gestiona variables con alta correlación en función de los análisis estadísticos, en el contexto de la mejora del rendimiento de modelos de Machine Learning.
	IL1.3 Gestiona los valores atípicos y faltantes en los datos utilizando métodos estadísticos o de imputación pertinentes, en el contexto del aseguramiento de la calidad del preprocesamiento de la información.

Resultados de aprendizaje e Indicadores de Logro

RESULTADO DE APRENDIZAJE	INDICADORES DE LOGRO
RA2 Implementa modelos de aprendizaje supervisado de regresión y clasificación utilizando algoritmos y métricas pertinentes en la resolución de problemas, con soluciones alineadas a los requerimientos organizacionales.	IL2.1 Aplica modelos de regresión con algoritmos (lineales y no lineales) y métricas de desempeño en el contexto de la resolución de problemas organizacionales.
	IL2.2 Aplica modelos de clasificación con algoritmos y métricas de desempeño en el contexto de la resolución de problemas organizacionales.
	IL2.3 Monitorea el rendimiento de algoritmos supervisados comparando métricas de desempeño, en el contexto de selección del modelo para resolver un problema de Machine Learning.

Resultados de aprendizaje e Indicadores de Logro

RESULTADO DE APRENDIZAJE	INDICADORES DE LOGRO
RA3 Integra técnicas de aprendizaje no supervisado, para segmentación, generación de nuevo conocimiento y reducción de la dimensionalidad de conjuntos de datos, en escenarios empresariales o de investigación.	IL3.1 Aplica técnicas de reducción de dimensionalidad, empleando algo ritmos lineales, no lineales y de selección de variables, en un conjunto de datos para proyectos empresariales o de investigación.
	IL3.2 Utiliza métodos de agrupamiento de datos utilizando algoritmos jerárquicos, basados en densidad y particionamiento, en el contexto de la segmentación de clientes, patrones o comportamientos organizacionales.
	IL3.3 Diagnostica la calidad de los agrupamientos generados utilizando índices de validación interna y externa en el contexto de la generación de nuevo conocimiento a partir de datos organizacionales o de investigación.

Evaluaciones

- **EA 1:**
EVALUACIÓN PARCIAL 1 - Encargo Exploración y Preprocesamiento de Datos (20%)
EVALUACIÓN PARCIAL 2 - Prueba Preprocesamiento de datos (15%)
- **EA 2:**
EVALUACIÓN PARCIAL 3 - Encargo Machine Learning Supervisado (10%)
EVALUACIÓN PARCIAL 4 - Presentación Machine Learning Supervisado (10%)
- **EA 3:**
EVALUACIÓN PARCIAL 5 - Encargo Aprendizaje No Supervisado (20%)
EVALUACIÓN PARCIAL 6 - Prueba ML supervisado y no supervisado (25%)
- **Examen final transversal:** Informe en Notebook completo/consolidado (30%) + Defensa oral final con calificación individual, con preguntas dirigidas del docente (70%)



Introducción




Introducción

Esta asignatura tendrá 3 grandes objetivos:

1. Preparar los datos para que algoritmos de Machine Learning (ML) puedan utilizarlos.
2. Estudiar y aplicar modelos de aprendizaje supervisado.
3. Estudiar y aplicar modelos de aprendizaje no supervisado.

¿Pero qué es el Machine Learning?

Machine Learning (ML)



"Un Campo de estudio que le da a los computadores la habilidad de aprender sin ser explícitamente programado"

- Arthur Samuel, 1959.

"Se dice que un programa A aprende de la experiencia E con respecto a una tarea T y una medida de desempeño P, si el desempeño en T, medido por P, mejora con E"

- Tom Mitchell, 1998


**Pero aún no es momento de aplicar Machine Learning.
Primero debemos preparar los datos.**

Preprocesamiento de datos

El preprocesamiento tiene varios nombres en la literatura:

- Limpieza de datos (Data cleaning)
- Preparación de datos (Data preparation)


- Esta etapa comúnmente en proyectos relacionados con datos es la que toma más tiempo.
- Estos proyectos comúnmente tienen una metodología a utilizar, y en la literatura existen varias.
- Estos proyectos están relacionado al proceso de minería de datos.
- Aquí nos concentraremos en la metodología: **CRISP-DM**



CRISP-DM

CROSS INDUSTRY STANDARD PROCESS FOR DATA MINING (CRISP DM) es una iniciativa financiada por la Comunidad Europea donde ha unido a diferentes empresas para desarrollar una plataforma para Minería de Datos.

NOTA: Dado que es un modelo sencillo, pero al mismo tiempo robusto, usaremos este modelo para el desarrollo de nuestros proyectos.



CRISP-DM


1. Comprensión del problema o negocio: Esta es la etapa más importante, ya que, si no se comprende correctamente el negocio, o problema, no servirá pasar a las siguientes etapas.

Sus actividades principales son:

Identificación del problema: Aborda el entendimiento y delimitación de la problemática, así como la identificación de los requisitos, restricciones, supuestos y beneficios del proyecto.

Determinación de objetivos: Establece los posibles resultados a obtener al proponer la solución.

Evaluación de la situación actual: Describe el estado actual antes de ser implementada la solución propuesta, con el fin de tener un objeto de comparación que permita medir el grado de éxito del proyecto.



CRISP-DM


2. *Comprensión de los datos:*

Comprende la recolección inicial de datos, con el objetivo de establecer un primer acercamiento con el problema, conociendo a los datos, identificando su calidad y estableciendo las primeras relaciones que permitan definir correlaciones entre variables.

Sus actividades principales son:

Recolección de datos: Consiste en obtener los datos a utilizar en el proyecto a partir de algunas fuentes de datos, e identificando las técnicas utilizadas para su recolección.

Exploración de datos: Se basa en aplicar pruebas estadísticas que permitan conocer las propiedades de los datos.




CRISP-DM

3. Preparación de datos: Esta es la etapa que demanda más tiempo en el proyecto, aquí se seleccionan los datos que serán transformados de acuerdo con los resultados de la etapa anterior a fin de ser utilizados en la etapa de modelado.

Sus actividades principales son:

Limpieza de datos: Para este fin se aplican diferentes técnicas, por ejemplo, normalización de datos, tratamiento de valores nulos, tratamiento de duplicados e imputación de datos.

Transformación de datos: Aquí se cambia la estructura o el formato de ciertos datos sin alterar su significado, a fin de poder ser utilizados en la etapa de modelado



CRISP-DM

4. Modelar: Esta etapa consiste en seleccionar, entrenar, ajustar y comparar modelos que permitan resolver el problema planteado. Aunque parece una etapa puramente técnica, está profundamente conectada con la etapa anterior (*Preparación de Datos*) y con la siguiente (*Evaluación*).

Sus actividades principales son:

Selección de las Técnicas de Modelado:


Aquí se decide **qué tipo de modelo** utilizar, dependiendo del tipo de problema, de los datos, y de las restricciones del negocio.

Diseño del Plan de Modelado:

Consiste en definir cómo vas a aplicar cada técnica elegida.

Construcción de los Modelos (Entrenamiento)

Aquí se entrenan los modelos usando los datos preparados.




CRISP-DM

5. *Evaluar:* esta etapa determina si los modelos seleccionados **responden a los objetivos del negocio** y son fiables, robustos y apropiados para producción. No basta con una buena métrica: hay que verificar validez, sesgos, costos y riesgos.

En esta etapa se revisa el proceso completo y se decide si es necesario volver a una etapa anterior, antes de pasar a la etapa de Implementación.

También se evalúan todos los resultados y se comparan con otras opciones de modelos que pudieron generarse.




CRISP-DM

6. Implementación: La etapa de implementación consiste en **poner en uso los resultados del proyecto**, lo que puede significar desde entregar un informe hasta instalar un modelo en producción. Esta fase implica aspectos técnicos, operacionales, éticos y organizacionales.

Algunas actividades destacables de esta etapa son:

Identificación de los responsables del proceso, la infraestructura necesaria, las dependencias técnicas, los riesgos operacionales y el esquema de comunicación hacia los usuarios finales o stakeholders relevantes

Ejecutar la puesta en marcha del sistema. Dependiendo del tipo de proyecto, esto puede implicar la integración de un modelo predictivo en un servicio web (API), la ejecución periódica de procesos de *batch scoring*, la incorporación de insights en dashboards o reportes, etc.






¿Qué se necesita
para el curso?



¿Qué usaremos?

$$P(X=x) = \frac{n!}{x!(n-x)!} p^x q^{n-x}$$




$$\hat{p} \pm z_{\alpha/2} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$


$$Z = \frac{X - \mu}{\sigma}$$



$$P(A|B) = \frac{P(A) \times P(B|A)}{\sum P(A) \times P(B|A)}$$



¿Qué usaremos?



$X_1^{(1)}$	$X_2^{(1)}$	$X_3^{(1)}$	$X_4^{(1)}$	$y^{(1)}$
$X_1^{(2)}$	$X_2^{(2)}$	$X_3^{(2)}$	$X_4^{(2)}$	$y^{(2)}$
$X_1^{(3)}$	$X_2^{(3)}$	$X_3^{(3)}$	$X_4^{(3)}$	$y^{(3)}$
.	.	.	.	.
.	.	.	.	.
.	.	.	.	.
$X_1^{(n)}$	$X_2^{(n)}$	$X_3^{(n)}$	$X_4^{(n)}$	$y^{(n)}$

$$\sigma_{jk} = \frac{1}{n} \sum_{i=1}^n \left(\frac{X_j^{(i)} - \mu_j}{\sigma_j} \right) \left(\frac{X_k^{(i)} - \mu_k}{\sigma_k} \right)$$

$$\Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \sigma_{13} & \sigma_{14} \\ \sigma_{21} & \sigma_2^2 & \sigma_{23} & \sigma_{24} \\ \sigma_{31} & \sigma_{32} & \sigma_3^2 & \sigma_{34} \\ \sigma_{41} & \sigma_{42} & \sigma_{43} & \sigma_4^2 \end{bmatrix}$$

$$y^{(i)} = \sum_{j=1}^4 X_j^{(i)} w_j \quad L = S_W^{-1} S_B$$

$$y = X w$$

$$R = X^T X$$

$$X^T y = R w$$

$$w = R^{-1} (X^T y)$$



¿Qué usaremos?



DuocUC[®]



CERCANÍA. LIDERAZGO. FUTURO.

7
AÑOS
ACREDITADO

 Comisión Nacional
de Acreditación
CNA-Chile

NIVEL DE EXCELENCIA
HASTA OCTUBRE 2031

Docencia de pregrado / Gestión institucional / Aseguramiento interno de la
calidad / Vinculación con el Medio / Investigación, creación y/o innovación