



Contenido

01


Estadística de los datos

02

Estadística descriptiva

03

Variables Categóricas



Introducción

La estadística descriptiva es una rama de la estadística que se enfoca en **recolectar, organizar, resumir y presentar datos de manera comprensible**. Sus principales conceptos incluyen medidas de tendencia central, como la media, mediana y moda; medidas de dispersión, como la varianza y desviación estándar; y herramientas gráficas, como histogramas y diagramas de dispersión. Estas técnicas permiten identificar patrones y características esenciales de un conjunto de datos sin realizar inferencias ni predicciones.

En el ámbito del **preprocesamiento de datos** y el **machine learning**, la estadística descriptiva es fundamental para analizar la calidad y estructura de los datos. Proporciona métricas y visualizaciones clave para detectar valores atípicos, entender la distribución de las variables y preparar los datos para algoritmos de aprendizaje automático. Este análisis inicial asegura una base sólida para la modelación, reduciendo errores y mejorando la precisión de los modelos.




Estadística de los datos



Estadística

Conjunto de técnicas y herramientas matemáticas que permiten recolectar, analizar e interpretar datos para apoyar procesos de **toma de decisiones**.



Se ocupa de recolectar, organizar y presentar los datos para su posterior análisis.

Métodos y procedimientos para deducir características de la población a partir de una muestra.

Datos

Según el Australian Bureau of Statistics, los **datos son un conjunto de valores** de variables cuantitativas o cualitativas sobre una o más persona u objetos.

Las variables que contienen datos, entonces, pueden ser:

- **Cuantitativas:** Aquellas con las que tiene sentido hacer operaciones aritméticas como sumar o multiplicar.
- **Cualitativas:** Las que no son cuantitativas. Usualmente sirven para categorizar a los individuos (sexo, color, especie, marca) o para identificar (nombre, número de identificación).

Los tipos de datos, tienen **diferente origen** y permiten hacer referencia al **tipo de información** que se maneja.



Datos estructurados y no estructurados

Los datos provienen de muchas fuentes: mediciones de sensores, eventos, texto, imágenes y videos.

Gran parte de estos datos no están estructurados:

- Las imágenes son una colección de píxeles, y cada píxel contiene información de color RGB (rojo, verde, azul).
- Los textos son secuencias de palabras y caracteres que no son palabras.


De hecho, un gran desafío de la ciencia de datos es **convertir este torrente de datos sin procesar en información procesable**.

Los datos sin estructura deben procesarse y manipularse en una forma estructurada.

Una de las formas más comunes de datos estructurados es una tabla con filas y columnas, ya que los datos pueden surgir de una base de datos relacional o recopilarse para un estudio.

Hay dos tipos de datos estructurados: **numéricos y categóricos**.

Datos estructurados y no estructurados



Conjunto de datos

- Un conjunto de datos (conocido también por el anglicismo **dataset**) es una **colección de datos** habitualmente tabulada.
- Los dataset tabulados son colecciones de **objetos** con sus **atributos**.
- Un **atributo** es una propiedad o característica de un objeto.
- Un **objeto** es una colección de atributos.

Atributos

Objetos

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Id	acidity	vacidity	citric	sugar	chlorides	fsd	tsd	density	pH	sulphates	alcohol	quality
1	7.4	0.7	0	1.9	0.076	11	34	0.9978	3.51	0.56	9.4	5
2	7.8	0.88	0	2.6	0.098	25	67	0.9968	3.2	0.68	9.8	5
3	7.8	0.76	0.04	2.3	0.092	15	54	0.997	3.26	0.65	9.8	5
4	11.2	0.28	0.56	1.9	0.075	17	60	0.998	3.16	0.58	9.8	6
5	7.4	0.7	0	1.9	0.076	11	34	0.9978	3.51	0.56	9.4	5
6	7.3	0.65	0	1.2	0.065	15	21	0.9946	3.39	0.47	10	7
7	8.3	0.675	0.26	2.1	0.084	11	43	0.9976	3.31	0.53	9.2	4
8	8.3	0.625	0.2	1.5	0.08	27	119	0.9972	3.16	1.12	9.1	4
9	10.1	0.31	0.35	1.6	0.075	9	28	0.99672	3.24	0.83	11.2	7



Estadística descriptiva



Medidas de tendencia central

- Las medidas de tendencia central son números que muestran (o intentan mostrar) dónde está el centro de los datos.
- Las más conocidas son: **la media (o promedio), la mediana y la moda.**
- Suponiendo que los valores son representados por x_i y n es el total de datos, la media se calcula como:

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{1}{n} \sum_{i=1}^n x_i$$

- La moda es el valor que más se repite entre todos los datos disponibles.
- La mediana dependerá si el número total de valores es par o impar.

IMPAR

1, 1, 1, 1, 1, 1, **2**, 2, 2, 2, 3, 3, 4

Mitad inferior Mediana Mitad superior


PAR

1, 1, 1, 1, 1, **1, 2**, 2, 2, 3, 3, 4

Valores inferiores Valores intermedios Valores superiores

Medidas de tendencia central

Gráficamente, podríamos ver estas cantidades así:



¿Qué pasa si hay valores muy alejados del centro de los datos?


Medidas de dispersión

Las **medidas de dispersión** tratan, a través del cálculo de diferentes fórmulas, de entregar un valor numérico que ofrezca información sobre el **grado de variabilidad** de una variable.

VARIANZA	DESVIACIÓN ESTÁNDAR
$\sigma^2 = \frac{\sum_1^N (x_i - \bar{X})^2}{N}$	$\sigma = \sqrt{\frac{\sum_1^N (x_i - \bar{X})^2}{N}}$
• X → Variable sobre la que se pretenden calcular la varianza. • x_i → Observación número i de la variable X. i puede tomará valores entre 1 y n. • N → Número de observaciones. • $\bar{X}$ → Es la media de la variable X.	
RANGO ESTADÍSTICO	COEFICIENTE DE VARIACIÓN
$R = Máx_x - Mín_x$ • R → Es el rango. • Máx → Es el valor máximo de la muestra o población. • Mín → Es el valor mínimo de la muestra o población estadística. • x → Es la variable sobre la que se pretende calcular esta medida.	$CV = \frac{\sigma_x}{ \bar{X} }$ • X → Variable sobre la que se pretenden calcular la varianza. • σ_x → Desviación típica de la variable X. • $\bar{X}$ → Es la media de la variable X en valor absoluto con $\bar{x} \neq 0$.

Medidas de dispersión

¿Cuál curva tiene mayor y menor varianza?



¿Qué podemos decir de la mediana y la moda?


Medidas de posición

Las medidas de posición son **indicadores estadísticos** que permiten resumir los datos en uno solo, o dividir su distribución en intervalos del mismo tamaño, por lo tanto, sirven para medir y para dividir.


Los más comunes son:

- **El cuartil (Q_i):** Es uno de los más utilizados y divide la distribución en cuatro partes iguales. Así, existen tres cuartiles. Los valores inferiores de la distribución se sitúan por debajo del primero (Q_1). La mitad o mediana son los valores menores iguales al cuartil dos (Q_2) y los superiores son representados por el cuartil tres (Q_3).
- **El decil (D_i):** Estamos ante un cuartil que divide los datos en diez partes iguales. Existen nueve deciles, de D_1 a D_9 . El D_5 se corresponde con la mediana. Por su lado, los valores superiores e inferiores (equivalentes a los diferentes cuartiles) se sitúan en puntos intermedios entre estos.
- **El percentil (P_i):** Por último, este cuartil divide la distribución en cien partes. Hay 99 percentiles. Tiene, a su vez, una equivalencia con los deciles y cuartiles.

Medidas de posición



Ejemplo de quintiles



Fuente: <https://stats.stackexchange.com/questions/470193/representing-quantile-like-quartile-in-form-of-normal-distribution-curve>

Correlación

El **coeficiente de correlación**, que da una estimación de la correlación entre dos variables que **siempre se encuentran en la misma escala**.

Para calcular el coeficiente de **correlación de Pearson**, multiplicamos las desviaciones de la media de la variable 1 por las de la variable 2 y dividimos por el producto de las desviaciones estándar.

El coeficiente de correlación siempre se encuentra entre +1 (correlación positiva perfecta) y -1 (correlación negativa perfecta); 0 indica que no hay correlación.

Las variables pueden tener una asociación que no sea lineal, en cuyo caso el coeficiente de correlación puede no ser una métrica útil.

$$r_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$



Variables categóricas



Variables Categóricas

Ejemplo:

1. Numérico:
 - a. Sexo (1 = Mujer, 2 = Hombre)
 - b. Resultados de una encuesta (1 = De acuerdo, 2 = Neutral, 3 = En desacuerdo)
2. Texto:
 - a. Formas de pago (Efectivo o Crédito)
 - b. Configuraciones de una máquina (Bajo, Medio, Alto)
 - c. Tipos de producto (Madera, Plástico, Metal)

Es importante identificar si una variable categórica es ordinal o no. Ya que en muchos casos será necesario transformar esa variable a números y los números deberán reflejar ese orden.

¿Cuáles variables del ejemplo son ordinales y cuáles no?

Variables Categóricas

- Con las **variables categóricas nominales** es posible calcular algunas estadísticas como:
 - Frecuencias: contar veces que aparece cada valor.
 - Moda: el valor que más se repite o con la frecuencia mayor.
- No tiene sentido calcular promedios, desviación estándar, cuartiles, etc. Esto reduce bastante el análisis que podemos hacer con respecto a la variable.
- Con las **variables categóricas ordinales** se puede hacer mucho más. Al transformarlas en número, es posible calcular varias estadísticas típicas y, como son ordinales, si pueden representar comportamientos de manera fidedigna.
- Veamos el ejemplo anterior: Configuraciones de una máquina (Bajo, Medio, Alto). Acá, los valores categóricos podrían tomar los siguientes valores:

Bajo = 0 ; Medio = 1 ; Alto = 2

- Los valores numéricos reflejan una cercanía que se cumple de igual manera en el caso de los valores categóricos. *Bajo* esta más cerca de *Medio* y más lejos de *Alto*. En el caso numérico, el 0 está más cerca del 1 y más lejos del 2.

Hay que considerar que algunos cálculos pueden generar números decimales. Estos resultados pueden aproximarse al momento de hacer una interpretación del resultado en la escala original (valores categóricos).

Variables Categóricas

- Finalmente, no solamente es posible pasar variables categóricas a numéricas, sino que a veces es recomendable pasar de variables numéricas a categóricas. Esto se llama: **Intervalos de clase**.
- Los intervalos de clase son divisiones que se hacen a la variable numérica. En específico al rango numérico que esta tiene. Veamos un ejemplo

- Como se ve, las clases se transforman en categorías ordinales.
- Ahora, se puede tratar como cualquier variable categórica ordinal.
- Esto es útil para resumir la información. Además, si poseemos información adicional del problema, esta división nos puede ayudar a encontrar patrones interesantes que se nos haría más difícil de encontrar si no hiciéramos esta división.

Intervalo de clase: Para agrupar los datos es necesario definir el limite inferior y superior de la clase. La diferencia entre los limites determina el intervalo.	
Clase X (Estatura)	Frecuencia F N° Estudiantes
60-62	5
63-65	18
66-68	42
69-71	27
72-74	8
Total	100

Número de clases: 5

En la clase 60-62 el límite inferior es: 60 y el límite superior es 62

Intervalo de clase: $62 - 60 = 2$

DuocUC[®]



CERCANÍA. LIDERAZGO. FUTURO.

7
AÑOS
ACREDITADO

 Comisión Nacional
de Acreditación
CNA-Chile

NIVEL DE EXCELENCIA
HASTA OCTUBRE 2031

Docencia de pregrado / Gestión institucional / Aseguramiento interno de la
calidad / Vinculación con el Medio / Investigación, creación y/o innovación