



Escalamiento y codificación
de variables
Machine Learning TLY1101


Contenido

01

Escalamiento de datos

02

Codificación de variables





Escalamiento de datos



Introducción

- Las **técnicas de escalamiento de datos** son fundamentales para garantizar que las variables utilizadas en un modelo estén en rangos comparables, evitando que algunas características dominen debido a su magnitud.
- Las variables de entrada pueden tener diferentes unidades (por ejemplo, pies, kilómetros y horas), lo que, a su vez, puede significar que las variables tienen escalas distintas.
- Las diferencias en las escalas de las variables de entrada pueden aumentar la dificultad del problema que se está modelando. Un ejemplo de esto es que valores de entrada grandes (por ejemplo, un rango de cientos o miles de unidades) pueden llevar a un modelo a aprender valores de pesos elevados.
- Un modelo con valores de pesos grandes suele ser inestable, lo que significa que puede sufrir un bajo rendimiento durante el aprendizaje.


Algoritmos sensibles a la escala, como los basados en distancia (e.g., K-Nearest Neighbors, SVM) o en optimización por gradiente (ANN).

Introducción

Beneficios del escalamiento de datos:

- **Mejor convergencia:** Los algoritmos basados en gradientes convergen más rápidamente cuando los datos están escalados.
- **Rendimiento más uniforme:** Reduce el sesgo hacia variables con valores mayores.
- **Estabilidad numérica:** Previene problemas computacionales asociados con cálculos en números muy grandes o muy pequeños.

Ejemplo: Si una variable está medida en kilómetros y otra en milímetros, la primera dominará el proceso de aprendizaje debido a sus valores más grandes, a pesar de que ambas puedan ser igualmente importantes para el modelo.



Métodos de escalamiento

Métodos de escalamiento

Existen varios métodos que se pueden aplicar dependiendo de las características de los datos y las necesidades del modelo.

Estudiaremos los siguientes métodos:

1. Normalización
2. Estandarización
3. Escalamiento robusto

Métodos de escalamiento: Normalización

Este método escala los datos para que estén en un rango específico, generalmente [0, 1]. Es útil cuando se desea conservar la distribución relativa de los datos.

$$x_{new} = \frac{x_{old} - x_{min}}{x_{max} - x_{min}}$$

Ventajas:

- Fácil de interpretar.
- Conserva la relación proporcional entre los valores originales.

Desventajas:

- Muy sensible a los valores atípicos, ya que Xmin y Xmax pueden distorsionarse si hay outliers.

Métodos de escalamiento: Estandarización

La estandarización transforma los datos para que tengan una media de 0 y una desviación estándar de 1. Es especialmente útil para modelos que asumen una distribución normal de los datos.

$$x_{new} = \frac{x_{old} - \mu_{old}}{\sigma_{old}}$$

Este procedimiento se hace a nivel de cada variable. Entonces, el dato antiguo se le resta la media y se divide por la desviación estándar.

Ventajas:


- Es robusto frente a la variabilidad en las magnitudes de los datos.
- No depende de un rango fijo, lo que lo hace útil para datos con distribuciones amplias.

Desventajas:

- Puede no ser adecuado para datos con distribuciones altamente asimétricas.

Métodos de escalamiento

Un ejemplo de cómo quedarían los datos después de una normalización o estandarización.



Un término más general a este proceso es: **Features Scaling**

Métodos de escalamiento: Escalamiento Robusto

Este método utiliza la mediana y el rango intercuartílico (IQR) en lugar de la media y la desviación estándar respectivamente, lo que lo hace más robusto frente a valores atípicos.

$$X_{new} = \frac{X - X_{median}}{IQR}$$

Donde el IQR (Interquartile Range) es la diferencia entre el percentil 75 y el percentil 25.

Ventajas:

- Insensible a los valores extremos.
- Conserva las características principales de la distribución.

Desventajas:

- Puede perder información sobre la variabilidad si los valores extremos son importantes.



Codificación de variables




Introducción

Hasta ahora, hemos identificado que las variables categóricas pueden clasificarse como **ordinales o nominales**. Aunque para un análisis exploratorio básico podríamos trabajarlas en su forma original, el panorama cambia cuando queremos realizar análisis más avanzados.

Para aplicar estadística inferencial o utilizar técnicas de machine learning para predecir comportamientos, es fundamental **transformar estas variables** categóricas en un formato que los algoritmos puedan interpretar.

En esta sesión, exploraremos 2 técnicas de codificación (**encoding**) que nos permitirán convertir estas variables en representaciones numéricas, facilitando su uso en análisis complejos y modelos predictivos



Introducción

Por qué es importante el encoding de datos:

- **Compatibilidad:** La mayoría de los algoritmos de machine learning no pueden procesar directamente datos categóricos o de texto, por lo que es necesario transformarlos en formatos numéricos para garantizar su funcionalidad.
- **Preservación del significado:** El encoding convierte las categorías en valores numéricos, asegurando que las relaciones y el significado inherente entre ellas se mantengan, especialmente en variables categóricas ordinales.
- **Eficiencia:** Las representaciones numéricas son más compactas y fáciles de procesar, lo que optimiza los tiempos de cálculo y mejora el rendimiento en tareas analíticas y predictivas.

Métodos de encoding

Métodos de encoding: Ordinal encoding

- **Ordinal encoding** es una técnica utilizada para convertir datos categóricos en datos numéricos asignando un número entero único a cada categoría dentro de una característica, basado en un orden o jerarquía significativa.

- Suponiendo que las distintas respuestas son:
Muy desacuerdo: 0
En desacuerdo: 1
De Acuerdo: 2
Muy de acuerdo: 3

Ventajas:

- Útil para categorías con un orden inherente.
- Conserva la relación jerárquica.

Desventajas:

- Puede ser inapropiado si las distancias entre categorías no son uniformes.

Encuesta	Ordinal Encoding
Muy de acuerdo	3
De acuerdo	2
En desacuerdo	1

Métodos de encoding: One-hot encoding

- **One-hot encoding** es una técnica popular para convertir datos categóricos en un formato numérico. Esta técnica es particularmente adecuada para características categóricas nominales donde las categorías no tienen un orden o jerarquía inherente.
- Al transformar una variable categórica nominal, se deben crear n variables adicionales. Una por cada valor.
- Indican con un 1 la presencia de la categoría y con 0 la ausencia.

Ventajas:

- No asume ninguna relación de orden entre categorías.
- Útil para categorías nominales (sin orden).

Desventajas:

- Incrementa la dimensionalidad si hay muchas categorías.

	Cat	Dog	Zebra
	1	0	0
	0	1	0
	0	0	1

DuocUC[®]



CERCANÍA. LIDERAZGO. FUTURO.

7
AÑOS
ACREDITADO

 Comisión Nacional
de Acreditación
CNA-Chile

NIVEL DE EXCELENCIA
HASTA OCTUBRE 2031

Docencia de pregrado / Gestión institucional / Aseguramiento interno de la
calidad / Vinculación con el Medio / Investigación, creación y/o innovación