



DuocUC[®] 

Valores atípicos

Machine Learning TLY1101

Contenido

01


Introducción

02

Métodos para detectar Outliers

03

Estadística con Outliers





Introducción



Introducción


- Al modelar, es importante limpiar la muestra de datos, para asegurarse de que las observaciones representen de la mejor manera el problema.
- A veces, un conjunto de datos puede contener valores extremos que están **fuera del rango de lo esperado** y que son diferentes del resto.
- Estos se denominan **valores atípicos (outliers)** y, a menudo, la modelización de aprendizaje automático y la habilidad del modelo en general pueden mejorarse comprendiendo e incluso eliminando estos valores atípicos.



Introducción

Los valores atípicos pueden tener muchas causas:

- Error de medición o entrada de datos.
 - Corrupción de los datos.
 - Observación de un valor atípico verdadero.
- No existe una forma precisa de definir e identificar los valores atípicos de manera general debido a las particularidades de cada conjunto de datos.
 - En su lugar, tú o un experto en el dominio deben interpretar las observaciones brutas y decidir si un valor es atípico o no.
 - Se debe tener mucho cuidado de no eliminar o modificar los valores apresuradamente, especialmente si el tamaño de la muestra es pequeño.




Introducción

La detección de valores atípicos juega un rol muy importante en varios campos:

- Detección de fraude financiero: fraude asociado a tarjetas de crédito,
- Detección de bots en redes sociales
- Vehículos autónomos, entre otros.

Por ejemplo, *la seguridad de redes informáticas se apoya cada vez más en la detección de valores atípicos para identificar intrusiones, fallos y patrones de uso nuevos. A diferencia del sistema tradicional basado en reglas, este enfoque es más flexible y capaz de detectar ataques desconocidos o de día cero.*

Series de tiempo que muestra una caída inesperada en el uso de la red (comportamiento anómalo).





Métodos para detectar Outliers



Métodos para detectar Outliers

Regla de los 3 sigmas: En una distribución normal, el 99.7% de los datos se encuentran dentro de 3 desviaciones estándar de la media. Los puntos fuera de este rango se consideran outliers.

Outliers si: $x < \mu - 3\sigma$ o $x > \mu + 3\sigma$

Percentiles (IQR - Rango Intercuartílico): Se usa el rango entre el primer cuartil (Q1) y el tercer cuartil (Q3). Los valores que están por debajo de $Q1 - 1.5 \cdot IQR$ o por encima de $Q3 + 1.5 \cdot IQR$ se consideran outliers.

Outliers si: $x < Q1 - 1.5 \cdot IQR$ o $x > Q3 + 1.5 \cdot IQR$

Métodos para detectar Outliers

- El **factor de atipicidad local** (*Local Outlier Factor* o **LOF**, por sus siglas en inglés) es una técnica que intenta aprovechar la idea de los **vecinos más cercanos** para la detección de valores atípicos.
- A cada ejemplo se le asigna una puntuación que indica qué tan aislado está o cuán probable es que sea un valor atípico, basada en el tamaño de su vecindad local.
- Los ejemplos con la puntuación más alta tienen más probabilidades de ser valores atípicos.
- La biblioteca **scikit-learn** proporciona una implementación de este enfoque a través de la clase **LocalOutlierFactor**.



Estadística con Outliers



Estadística con Outliers

- Los valores atípicos a menudo pueden desviar nuestras percepciones, convirtiendo lo que debería ser un análisis significativo en una conclusión engañosa.
- Una vez detectados los Outliers, debemos seguir nuestro análisis, realizando los cálculos pertinentes.
- No siempre lo recomendado es eliminar los datos que sean considerados outliers.
- Las opciones son:
 - Ignorar
 - Truncar
 - Winsorizar

Estadística con Outliers

- **Ignorar:** simplemente los datos outliers no se consideran en el análisis estadístico de los datos.
- **Truncar:** es parecido a ignorar, pero se define un porcentaje de valores a ignorar. Por ejemplo, si tenemos 10 valores y deseamos truncar al 10%, entonces se ignora el valor extremo menor y mayor. Si truncamos al 20%, ignoramos los dos valores más extremos por ambos lados (menor y mayor).
- **Winsorizar:** la diferencia se traduce en que acá no se ignoran los valores, si no que los valores extremos, definidos por un porcentaje al igual que “Truncar”, se reemplazan por un valor determinado. Por ejemplo, en una winsorización del 5%, el 5% más bajo de los puntos de datos se sustituye por el valor del percentil 5, y el 5% más alto se sustituye por el valor del percentil 95.

DuocUC[®]



CERCANÍA. LIDERAZGO. FUTURO.

7
AÑOS
ACREDITADO

 Comisión Nacional
de Acreditación
CNA-Chile

NIVEL DE EXCELENCIA
HASTA OCTUBRE 2031

Docencia de pregrado / Gestión institucional / Aseguramiento interno de la
calidad / Vinculación con el Medio / Investigación, creación y/o innovación