




Valores faltantes
Machine Learning TLY1101




Contenido

01

Introducción

02

Técnicas de imputación de MV






Introducción



Introducción

- El fenómeno de **datos faltantes (Missing Values en inglés)** se refiere a la ausencia de valores en ciertas observaciones dentro de un conjunto de datos.
- Esto es un problema común en el análisis de datos y en el desarrollo de modelos predictivos, ya que la calidad y la completitud de los datos son fundamentales para obtener resultados precisos y confiables.
- Manejar los datos faltantes es importante, ya que muchos algoritmos de aprendizaje automático no soportan datos con valores faltantes.



De ahora en adelante, nos referiremos a Missing Values con las siglas MV.

Introducción

A pesar de la respuesta obvia en este caso, los MV pueden generarse por distintas razones como:

- Fallas en capturar datos por efectos ambientales o fallas de hardware (redes de sensores).
- No dar respuesta por decisión propia (redes sociales).
- Prohibición por protocolos (hospitales).
- Falta de recursos: dinero, tiempo o máquinas (hospitales, observatorios, etc.)

ID	Color	Weight	Broken	Class
1	Black	80	Yes	1
2	Yellow	100	No	2
3	Yellow	120	Yes	2
4	Blue	90	No	2
5	Blue	85	No	2
6	?	60	No	1
7	Yellow	100	?	2
8	?	40	?	1

df				
	column_a	column_b	column_c	column_d
0	1.0	1.2	a	True
1	2.0	1.4	?	True
2	4.0	NaN	c	NaN
3	4.0	6.2	d	None
4	NaN	NaN	--	False
5	NaN	1.1	NaN	True
6	6.0	4.3	d	False

Introducción: problemas generados por MV

Pérdida de información:

- Los valores faltantes reducen la cantidad de datos disponibles para el análisis, lo que puede disminuir la potencia estadística.

Introducción de sesgos:

- Si los datos faltantes no son aleatorios, los resultados pueden estar sesgados.

Complejidad en el análisis:

- Los modelos de aprendizaje automático y estadísticos suelen requerir datos completos, lo que complica su implementación.

Dificultad en la interpretación:

- La falta de datos puede generar incertidumbre sobre los patrones reales presentes en el conjunto de datos.

Introducción: estrategias para manejar MV

Existen 4 grandes enfoques:

- **Eliminar los ejemplos (o variables) con MV**: sencillo, pero no se puede aplicar siempre. Solo cuando el porcentaje de MV es pequeño para cuando queramos eliminar ejemplos. Si queremos eliminar una variable, debe tener muchos datos faltantes esa variable.
- **Imputación del MV**: el MV se estima con alguna técnica de estimación de datos. Puede ocurrir que la estimación sea tan mala que sea peor el remedio que la enfermedad.
- **Trabajar con los datos tal cual vienen (sin eliminar, sin imputar)**: aquí todo el trabajo se lo lleva el clasificador, regresor u otro algoritmo. Añade complejidad al algoritmo y, además, puede producir sesgo.
- **Análisis específico de datos faltantes**: Investigar la causa de los datos faltantes y tratar de ajustar el análisis a esta información.



Técnicas de imputación






Técnicas de imputación

- » **Zero:** imputa con cero si hay MV. La técnica más simple (y peor) de imputación. No lo haga a no ser que los datos estén estandarizados....

¿Por qué?

- » **Media (mediana sigue la misma estrategia):** es mejor, pero cuidado con el efecto que puede producir.



Técnicas de imputación: KNN

K-NN significa **K-Nearest Neighbors**, lo que en español es **K vecinos más cercanos**.

K-NN es un método ampliamente utilizado en la literatura para diversas tareas, como por ejemplo:

- » Imputación de datos.
- » Clasificación, Regresión, Clustering

Veremos como funciona de manera general y luego veremos su aplicación en imputación.

Técnicas de imputación: KNN

K-NN tiene 2 parámetros importantes:

- **La medida de distancia o similaridad.**
- **El parámetro “K” o “e” según como se decida crear los vecindarios.**

El concepto de similaridad o distancia son parecidos, ya que tratan de cuantificar lo mismo, pero de puntos de vistas distinto.


- La distancia entre más crece, *más alejados o distintos son los objetos a medir.*
- La similaridad entre más crece, *más parecidos o cercanos son los objetos a medir.*

Existen diversas formas de calcular estas métricas. Aca veremos algunas.

Técnicas de imputación: KNN

Estrategia para crear vecindarios.

La más tradicional es usar el parámetro K: Esto se basa en elegir los K vecinos más cercanos según una métrica de distancia o similitud.



En este ejemplo, el punto negro central busca los $K=6$ vecinos más cercanos en un espacio de 2 dimensiones.

Esos puntos serían su vecindario.

DuocUC[®]



CERCANÍA. LIDERAZGO. FUTURO.

7
AÑOS
ACREDITADO

 Comisión Nacional
de Acreditación
CNA-Chile

NIVEL DE EXCELENCIA
HASTA OCTUBRE 2031

Docencia de pregrado / Gestión institucional / Aseguramiento interno de la
calidad / Vinculación con el Medio / Investigación, creación y/o innovación