

DuocUC

Regresión y sus métricas

Machine Learning TLY1101

Contenido

01

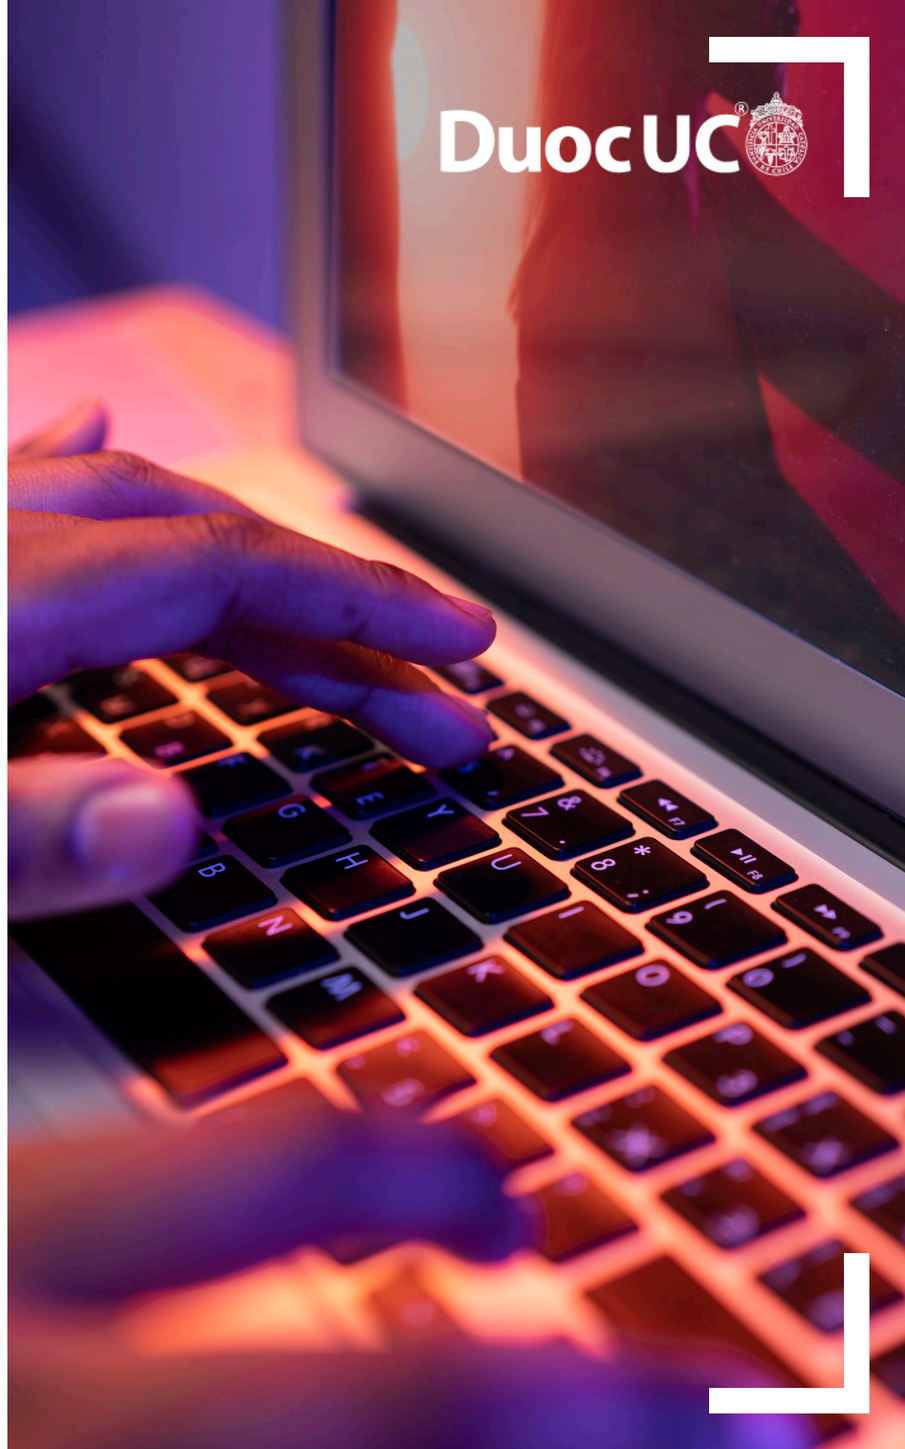
El problema de regresión

02

Métricas de regresión

03

Datos de entrenamiento y prueba



DuocUC®

<> ESCUELA DE INFORMÁTICA Y TELECOMUNICACIONES

El problema de regresión

Regresión Lineal

En estadísticas, regresión lineal es una aproximación para modelar la relación entre una variable escalar dependiente “Y” y una o más variables explicativas nombradas con “X”.

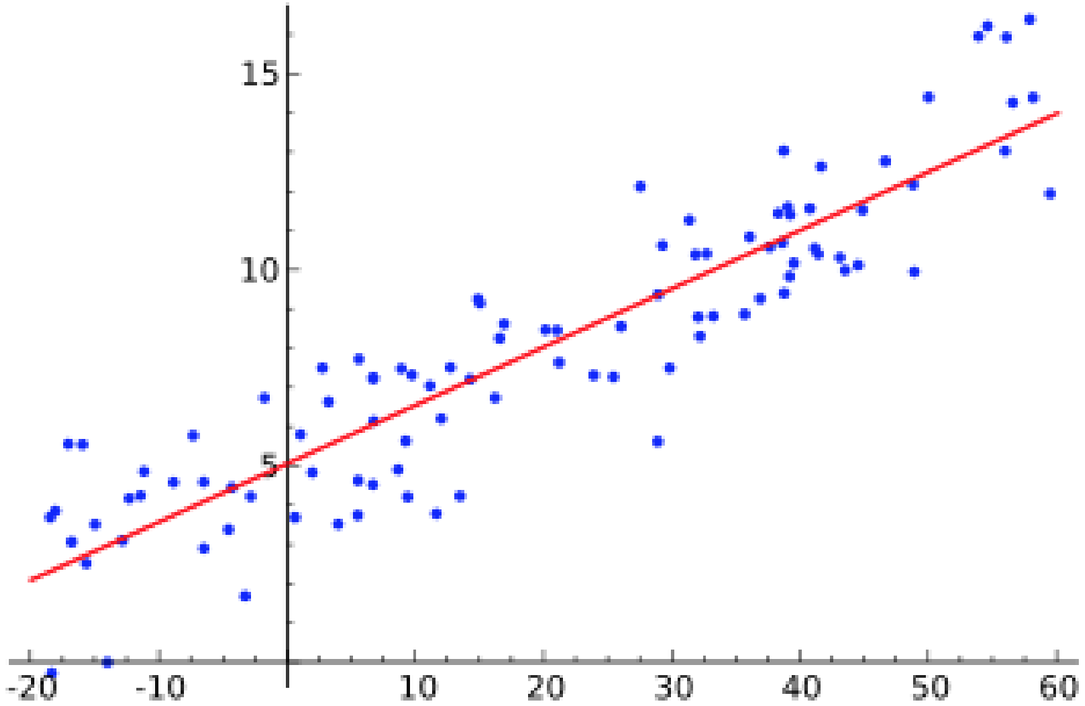
Matemáticamente hablando, tendremos:

Y: Variable dependiente

$X = \left(X_1, X_2, \ldots, X_D \right)$: Las D variables independientes

$$Y = f(X) + \varepsilon$$

Puedo modelar la variable Y mediante la función f() más un término de error (que en la práctica se omite).



La idea es encontrar la función f()

Regresión Lineal

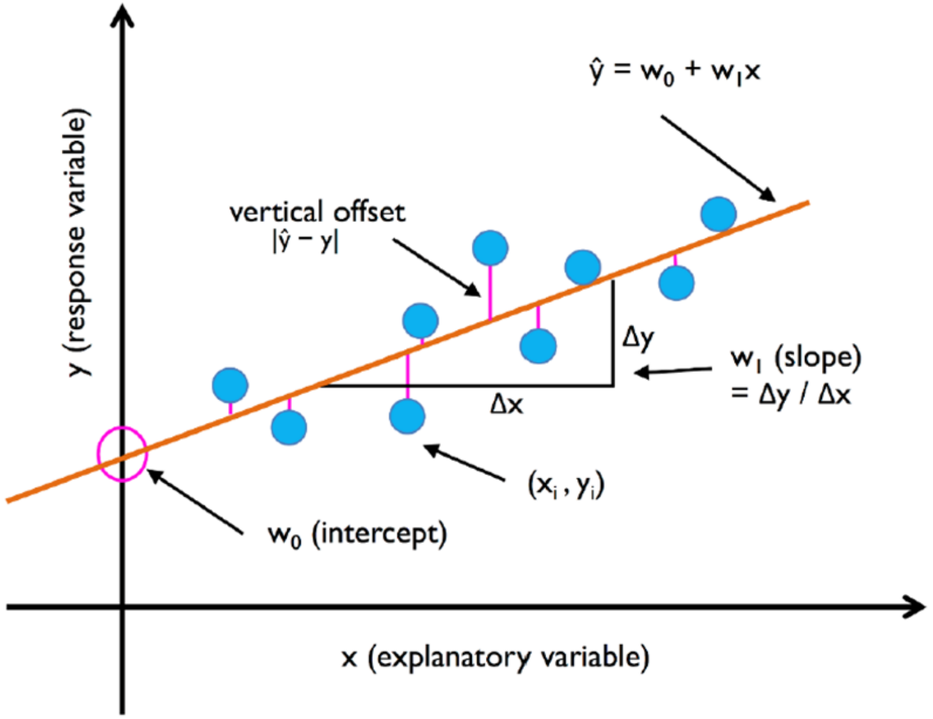
El escenario más sencillo con el que nos podemos encontrar es el de una variable dependiente y una única variable independiente, que siguen una relación aproximadamente lineal, salvo ruido (típicamente, normalmente distribuido).

La ecuación que representa este modelo, se puede expresar de la siguiente forma (sin el error e):

$$\hat{Y} = w_0 + w_1 x$$

Donde :

- $\hat{Y}$, es el resultado
- X, es la variable
- w_1, es la pendiente o coeficiente de la recta
- w_0 es la constante, conocida como ”punto de corte con el eje Y” o intercepto



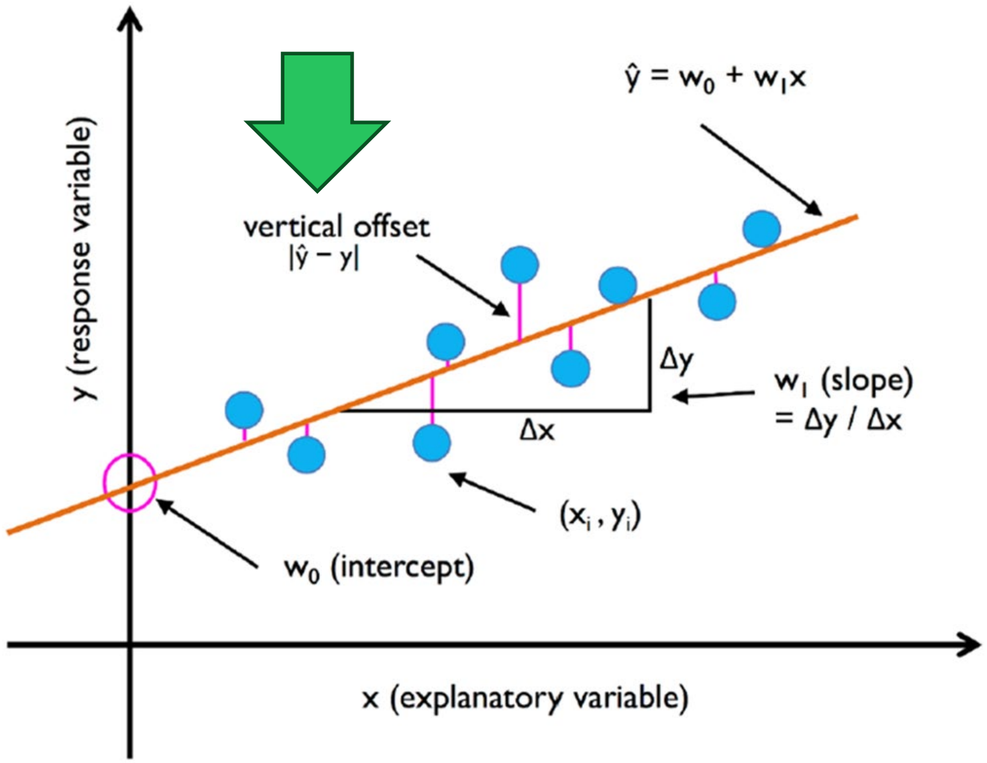
Regresión Lineal

Los algoritmos de Machine Learning supervisados, aprenden por sí mismos – en este caso- a obtener automáticamente la recta que se busca con la tendencia de la predicción.

Para hacerlo se mide el error con respecto a los puntos de entrada y el valor de “Y” de salida real.

La diferencia entre el valor “Y” de un punto real y el valor predicho de “Y”, se denomina *residuo* (vertical-offset en el gráfico).

Los parámetros del modelo se obtienen a partir de la ***minimización de la suma de los cuadrados*** **de los residuos**.



Regresión Lineal

Una forma es la llamada solución analítica simple, para el caso de 1 variable independiente

$$w_1 = \frac{\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y})}{\sum_{i=1}^{n}(x_i - \overline{x})^2}$$

$$w_0 = \bar{y} - w_1 \bar{x}$$

Además, está la forma matricial, donde se puede abordar la solución con más variables independientes

$$\hat{y} = w_0 + w_{1_l} + w_2 x_l + \cdots + w_p x_p$$

$$w = \left(\boldsymbol{X}^T \boldsymbol{X}\right)^{-1} \boldsymbol{X}^T y$$

Regresión Lineal

La forma matricial anteriormente expuesta se describe como: $\hat{y} = w_0 + w_{1_l} + w_2 x_l + \cdots + w_p x_p$

Y esta puede ser expresada como un sistema de ecuaciones:

$$\tilde{y} = \boldsymbol{X}\boldsymbol{w} + \varepsilon$$

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \quad \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \quad \begin{pmatrix} w_0 \\ w_1 \\ \vdots \\ w_p \end{pmatrix} \quad \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

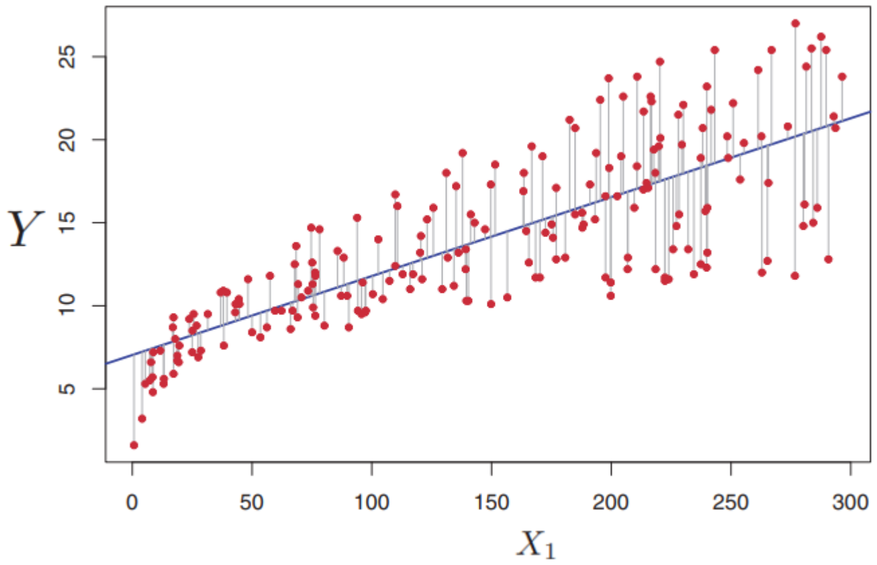
Vector de la variable dependiente | Matriz de diseño | Vector de parámetros | Vector de errores

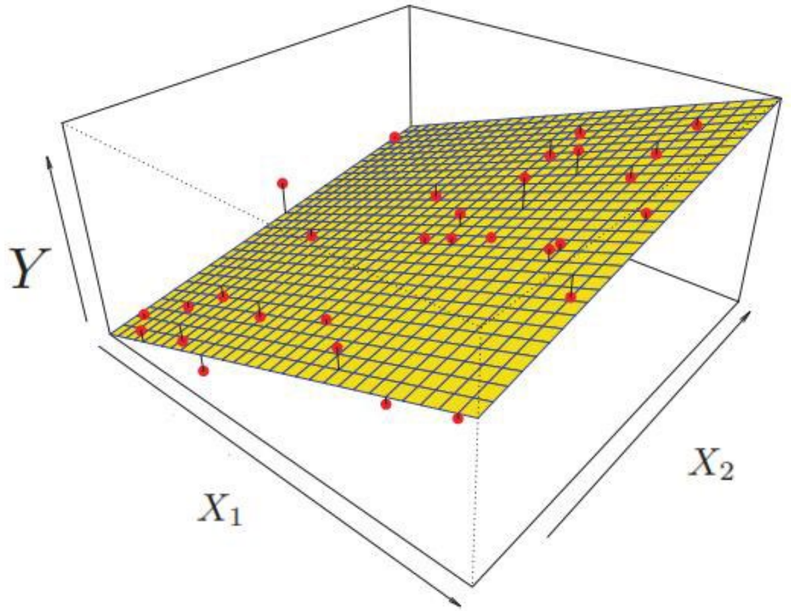
¿Cómo llegamos a esto?

$$w = \left(X^T X\right)^{-1} X^T y$$

Regresión Lineal

Dependiendo del número de variables independientes del modelo, la regresión lineal graficará una recta (1 variable), un plano (2 variables) o un **Hiperplano (3 o más variables)**





Regresión Lineal

En el **modelo de regresión lineal clásica**, la validez de las estimaciones y de la inferencia estadística descansa en una serie de **supuestos fundamentales. Algunos de estos son:**

- **Linealidad del modelo**
  La relación entre la variable dependiente y y las variables independientes x es lineal en los parámetros.

- **Homoscedasticidad**
  La varianza de los errores es constante para todos los niveles de las variables explicativas:

$$\text{Var}(\varepsilon \mid X) = \sigma^2$$

- **No multicolinealidad perfecta**
  Las variables independientes no presentan relaciones lineales exactas entre ellas. La multicolinealidad perfecta impide la estimación de los coeficientes.

DuocUC®

<> ESCUELA DE INFORMÁTICA Y TELECOMUNICACIONES

Métricas de regresión

DuocUC

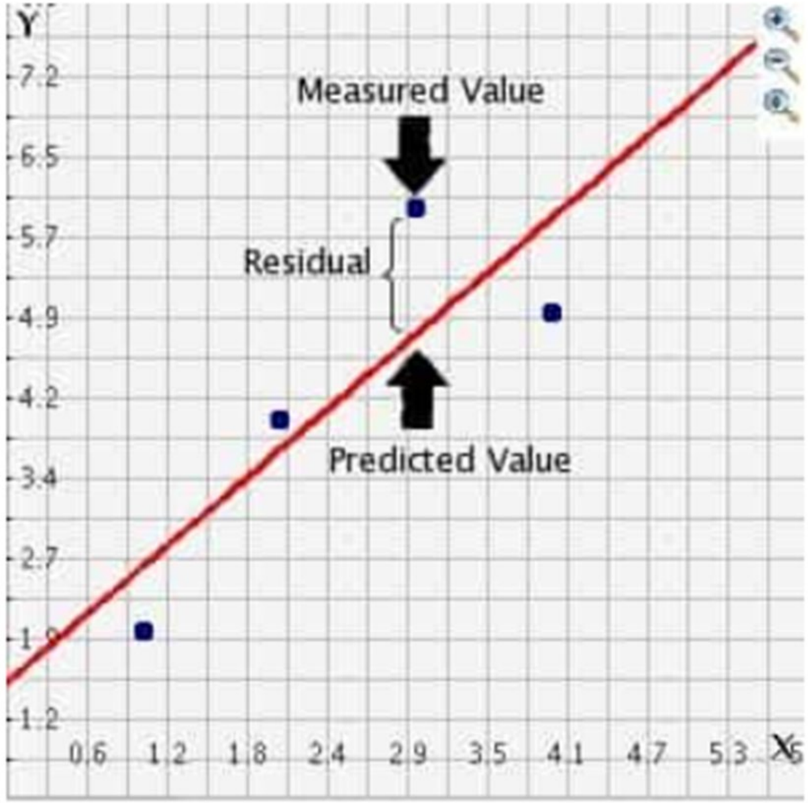
Métricas de regresión

Verificar un modelo de regresión lineal, nos permite ver en forma rápida, con algunos cálculos estadísticos, si es modelo es “bueno” respecto a su ajuste. Es decir, podemos verificar cuán certero es su ***desempeño***.

Este desempeño, podemos expresarlo en base a **métricas**.

La mayoría de estas métricas trabajan con el concepto ya visto denominado residuo. El cual refleja **la diferencia entre los valores observados y los valores que predice el modelo**.

En esta presentación, revisaremos las métricas más usadas en regresión incluyendo las funciones respectivas de sckikit-learn.



Link a scikit-learn

scikit learn

DuocUC

Métricas de regresión

MSE (Mean Square Error):

$$MSE = \frac{1}{N}\sum_{i=1}^{N}\left(y_i - \widehat{y_i}\right)^2$$

En scikit-learn: sklearn.metrics.mean_squared_error

MAE (Mean Absolute Error):

$$MAE = \frac{1}{N}\sum_{i=1}^{N}\left|y_i - \widehat{y_i}\right|$$

En scikit-learn: sklearn.metrics.mean_absolute_error

Métricas de regresión

R2 (Coeficiente de determinación):

$$R^2 = 1 - \frac{\sum_{i=1}^{N} \left(y_i - \hat{y}_i \right)^2}{\sum_{i=1}^{N} \left(y_i - \bar{y} \right)^2}$$

En scikit-learn: sklearn.metrics.r2_score

R2 ajustado:

$$R^2_{\alpha} = 1 - \left(\frac{N-1}{N-D-1} \right) \times \left(1 - R^2 \right)$$

La ventaja es que R2 ajustado no aumenta en función al número de variables que incorpora el modelo y R2 si.

Métricas de regresión

MAPE (Mean Absolute percentage Error):

$$MAPE = \frac{100\%}{N} \sum_{i=1}^{N} \left| \frac{y_i - \widehat{y_i}}{y_i} \right|$$

MAPE entrega un error relativo ya que divide la diferencia absoluta por el valor real.

Cuidado con los valores muy pequeños de y_i

DuocUC®

<> ESCUELA DE INFORMÁTICA Y TELECOMUNICACIONES

Datos de entrenamiento (train) y prueba (test)

Datos de train y test

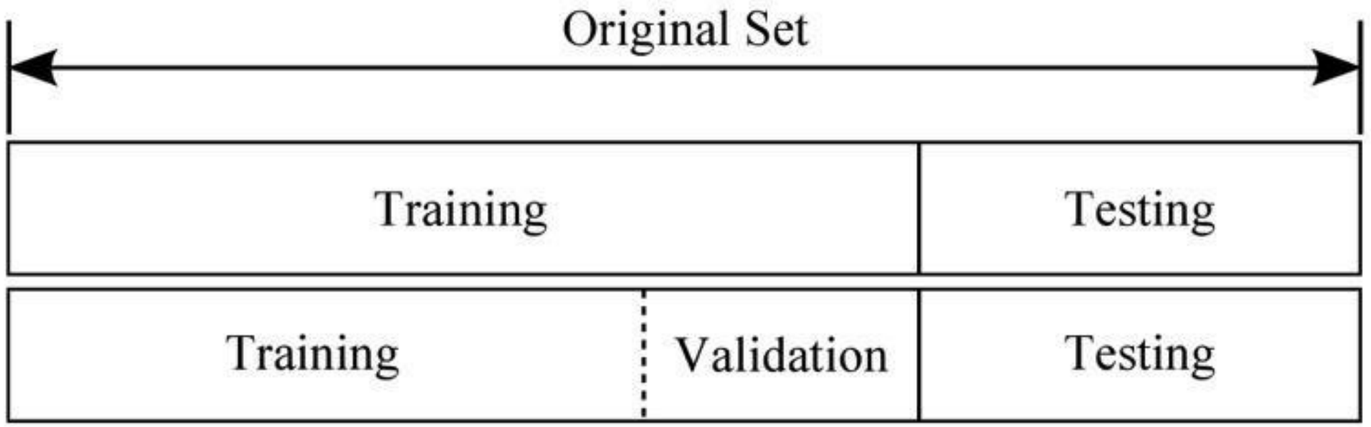
Los datos originales será nuestro 100%

De este 100%, dividiremos los datos en training set y testing set ¿En qué porcentaje?:

- El training set varía entre 60% y 80% y el testing set entre 40% y 20% respectivamente.
- El porcentaje se elige según la cantidad de datos que se tienen, el algoritmo a utilizar y cualidades particulares de los datos.

Es importante recalcar que el testing set nunca será ocupado sino hasta en la fase final.

El training set a veces se subdivide en: Training set y Validation set.



Datos de train y test

La división realizada de los datos originales a veces se le da el nombre de *shuffle.*

Un *shuffle* entonces es la partición de los datos originales en *training set* y *testing set*. De manera aleatoria o pseudo-aleatoria.

Para obtener resultados más robustos, se acostumbra a generar muchos *shuffles* con los mismos datos originales.

Con esto, y como es aleatorio, cada *shuffle* será distinto.

Así, al reportar los resultados, se podrán calcular una media y varianza de estos. En definitiva, una estadística de los resultados.

Datos de train y test

¿Se recuerda de la normalización y estandarización de los datos? Bueno, acá se debe utilizar ¿Cómo?

Se debe realizar al training set de manera separada al testing set.

Una vez realizada la normalización o estandarización al training set, se debe guardar los parámetros según cada modelo.

A modo de ejemplo, si quisiéramos escalar los datos entre 0 y 1 (MinMaxScaler), tendríamos que hacer lo siguiente:

$$X^{te}_{new} = \frac{X^{te}_{old} - X^{tr}_{min}}{X^{tr}_{max} - X^{tr}_{min}}$$

Donde:

$X^{te}_{(\cdot)}$: son datos de prueba (testing).

$X^{tr}_{(\cdot)}$: son datos de entrenamiento (training).

Datos de train y test

Lo anterior no solo se cumple para el escalamiento de variables, sino también para:

- ❖ Codificación de variables.
- ❖ Imputación de datos faltantes.
- ❖ Reducción de dimensionalidad y selección de características (lo veremos más adelante).

Esto es muy importante cuando el algoritmo se pasa a fase de producción, ya que los datos originales no llegan preprocesados.

Se deben preprocesar con los mismos métodos y parámetros utilizados en la fase de entrenamiento.

<> ESCUELA DE **INFORMÁTICA Y TELECOMUNICACIONES**

DuocUC®

CERCANÍA. LIDERAZGO. FUTURO.

7 AÑOS ACREDITADO

Comisión Nacional de Acreditación CNA-Chile

NIVEL DE EXCELENCIA

HASTA OCTUBRE 2031

Docencia de pregrado / Gestión institucional / Aseguramiento interno de la calidad / Vinculación con el Medio / Investigación, creación y/o innovación