

DuocUC

Clasificación

Machine Learning TLY1101

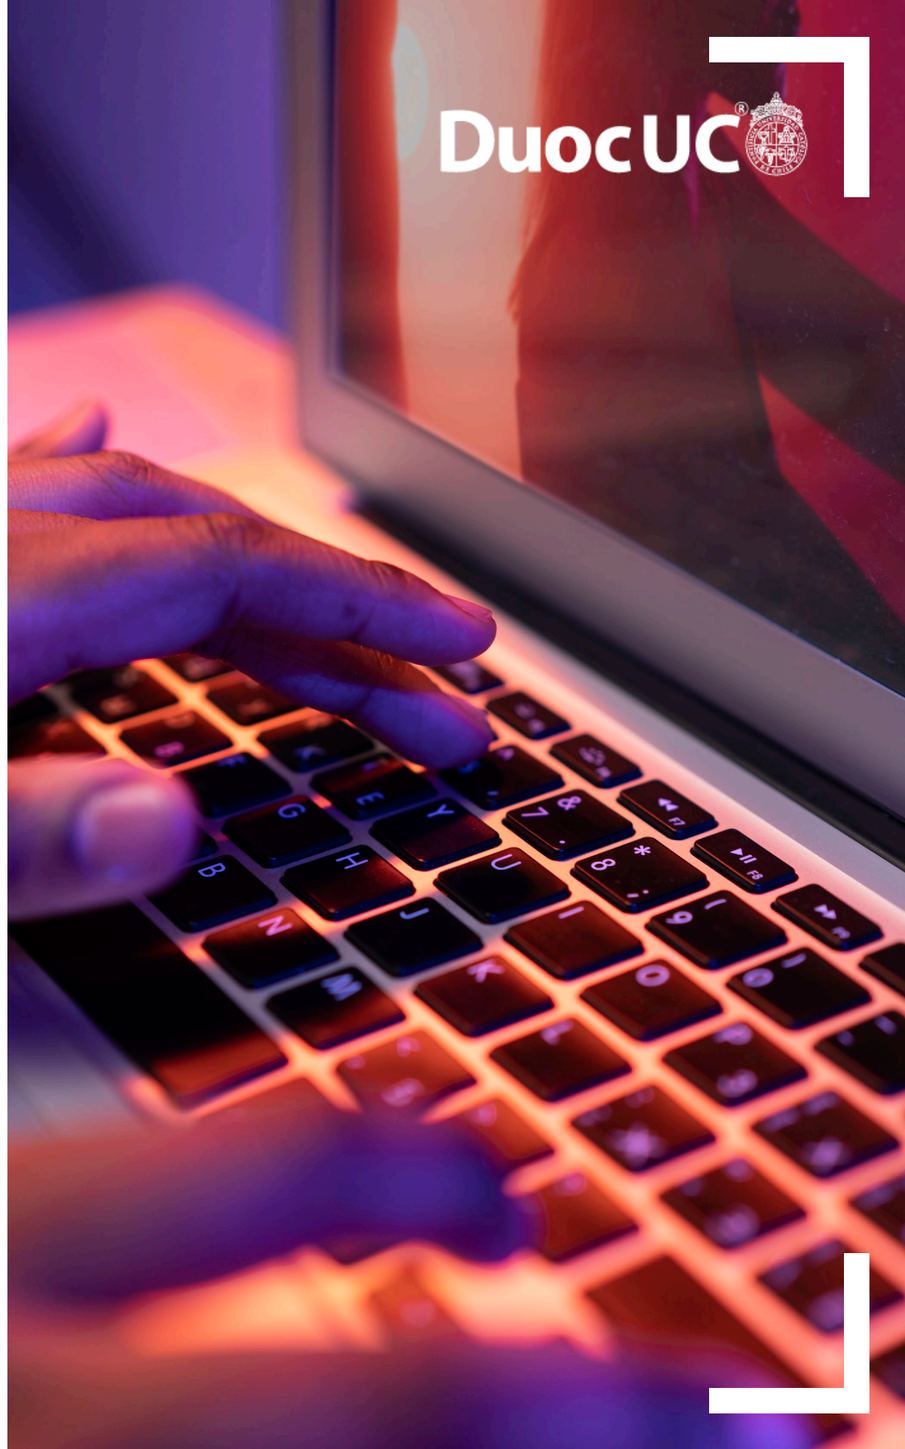
Contenido

01

El problema de clasificación

02

Algoritmo 1: Regresión logística



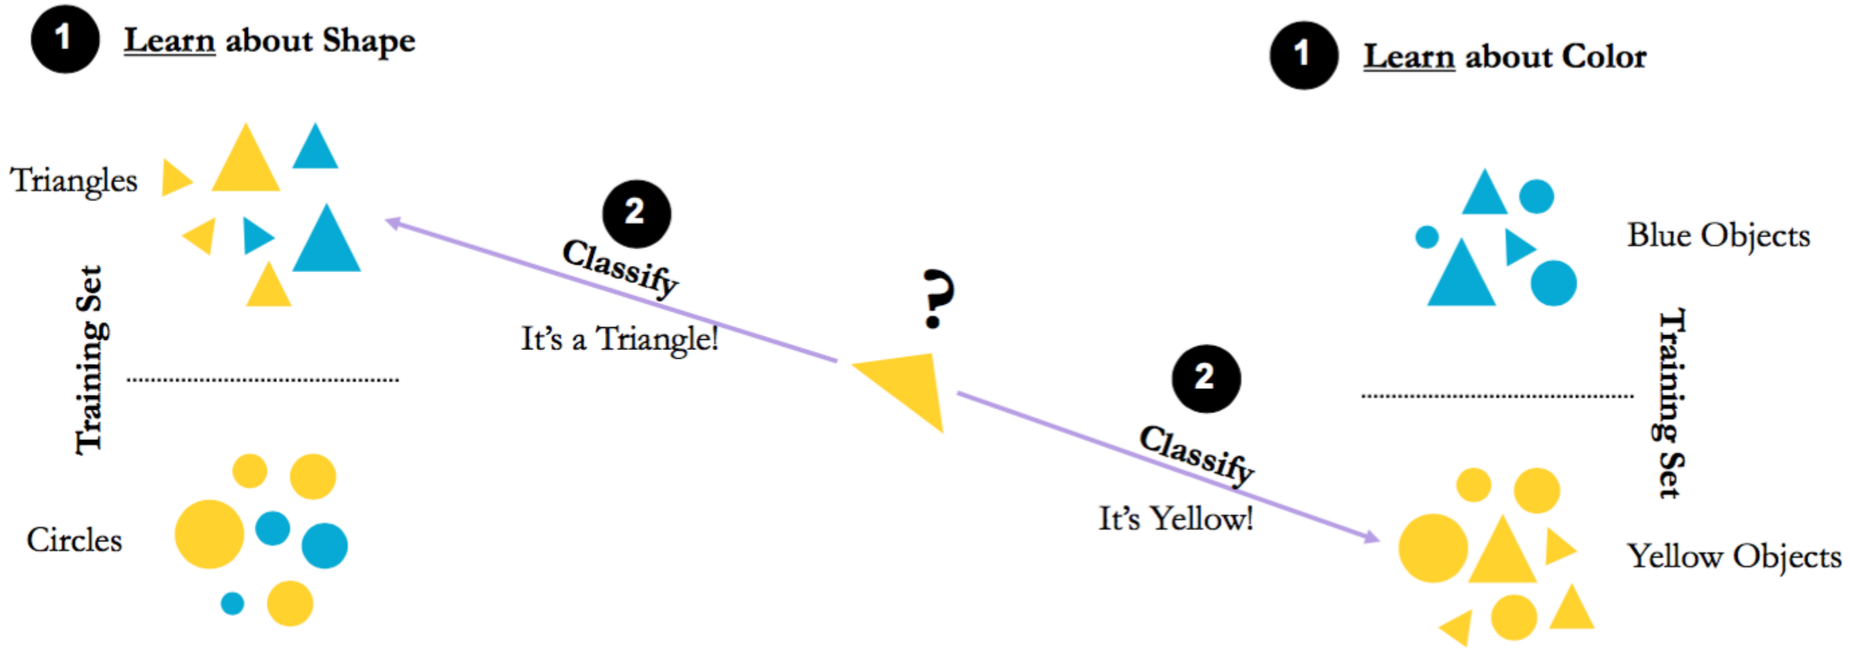
El problema de clasificación

El problema de clasificación

Previously in Machine Learning...

Aprendizaje Supervisado

Un maestro provee conjuntos de entrenamiento etiquetados, usados para *entrenar* un clasificador



La principal diferencia con regresión es que en clasificación la variable dependiente es una variable categórica.

El problema de clasificación

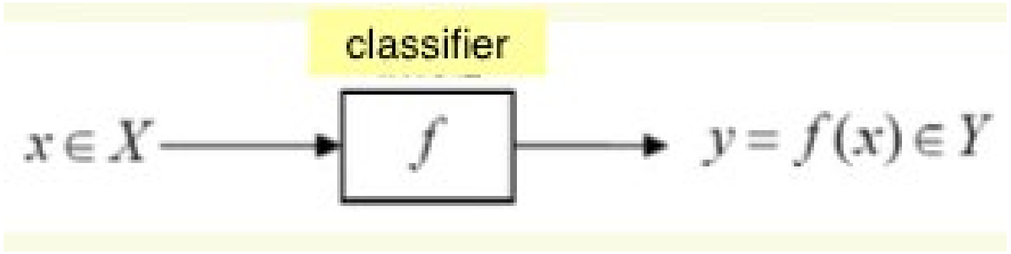
Matemáticamente:

Un clasificador es una función $f : X \longrightarrow Y$

X es el espacio de entrada, y $x \in X$ es dato del espacio de entrada.

Un dato del espacio de entrada es un x tal que $x = \{x_1, x_2, ..., x_D \mid c_k\} \in \mathbb{R}^{D+1}$ donde D es la dimensión del dato y c_k es la etiqueta (o clase) k del dato.

Ω es un conjunto finito de etiquetas tal que $\Omega = \{c_1, ..., c_k, ..., c_K\}$ y K es el número de etiquetas distintas existentes en el conjunto finito Ω .

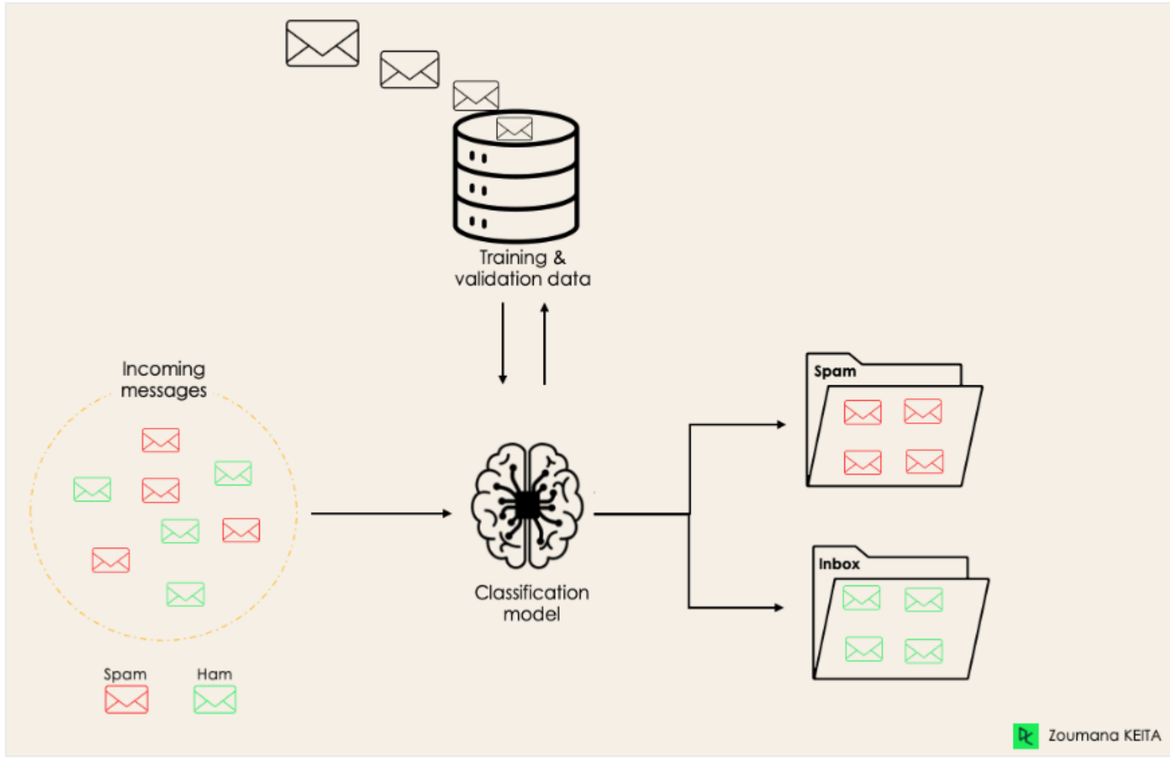


El problema de clasificación

Clasificación es un **tipo de tarea en aprendizaje automático supervisado** en el que el modelo intenta **predecir la etiqueta (o clase)** correcta de unos datos de entrada determinados.

En la clasificación, tradicionalmente el modelo se entrena por completo con los datos de entrenamiento y luego se evalúa en datos de prueba antes de usarse para realizar predicciones en nuevos datos no vistos.

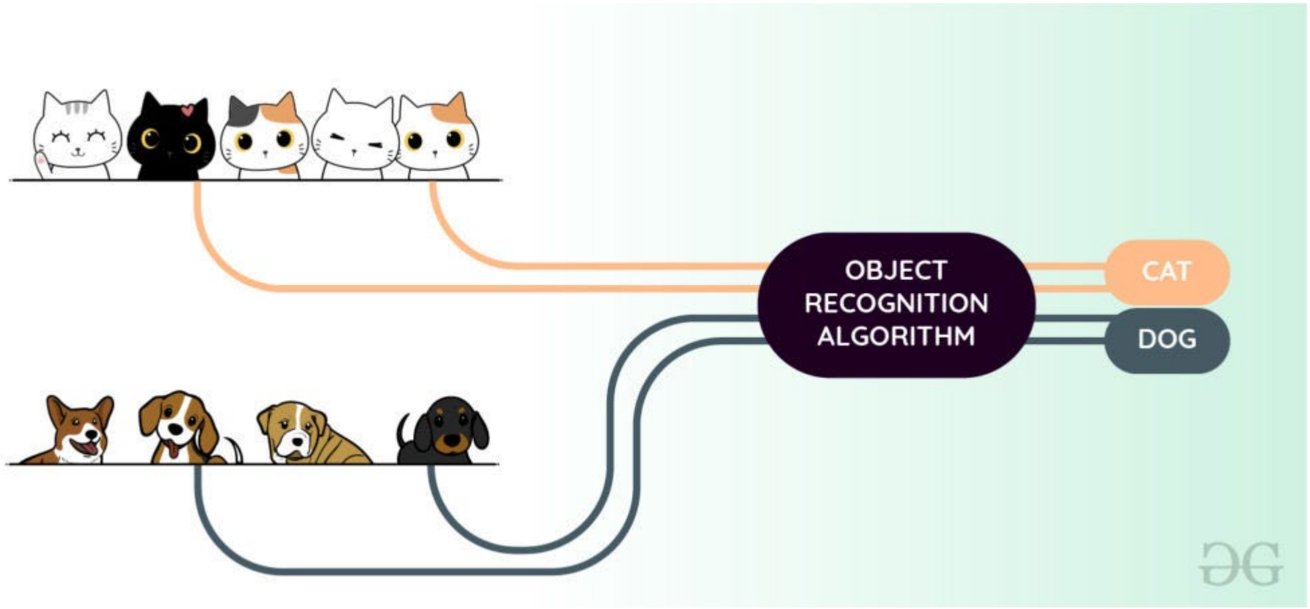
Por ejemplo, un algoritmo puede aprender a predecir si un correo electrónico determinado es spam o no, como se ilustra a continuación.



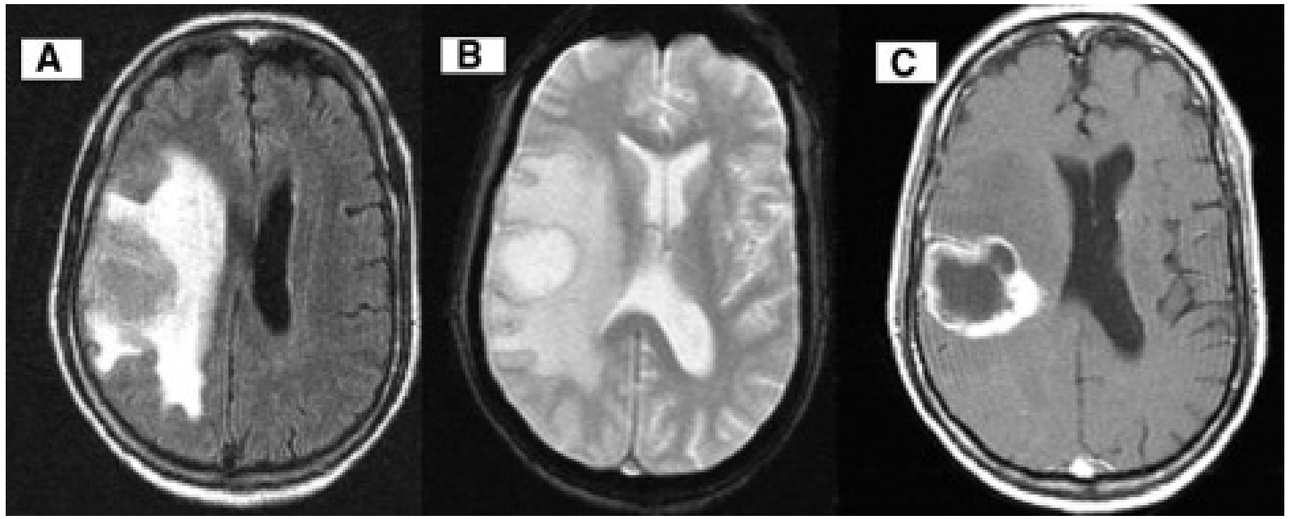
FUENTE: https://www.datacamp.com/blog/classification-machine-learning

El problema de clasificación

Images recognition



Tumor recognition



El problema de clasificación

SALUD

Entrenar un modelo de aprendizaje automático con datos históricos de pacientes puede ayudar a los especialistas de la salud a analizar con precisión sus diagnósticos.

Durante la pandemia de COVID-19, se implementaron modelos de aprendizaje automático para predecir de manera eficiente si una persona tenía COVID-19 o no.



El problema de clasificación

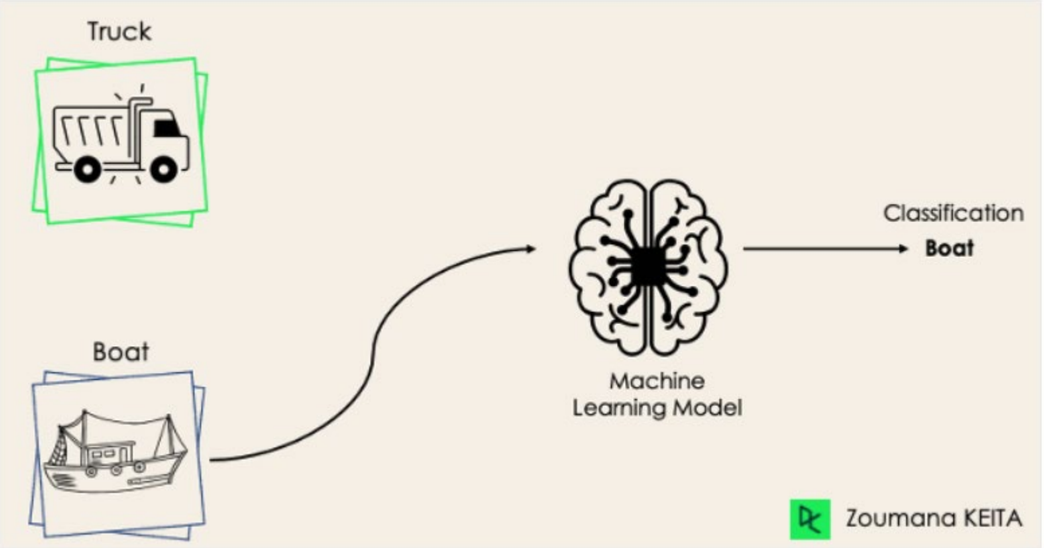
Tipos de clasificación

CLASIFICACIÓN BINARIA

En una tarea de clasificación binaria, el objetivo es clasificar los datos de entrada **en dos categorías mutuamente excluyentes**.

Los datos de entrenamiento en tal situación se etiquetan en formato binario: verdadero y falso; positivo y negativo; 0 y 1; spam y no spam, etc. según el problema que se aborde.

Por ejemplo, podríamos querer detectar si una imagen dada es un camión o un bote.



FUENTE: https://www.datacamp.com/blog/classification-machine-learning

El problema de clasificación

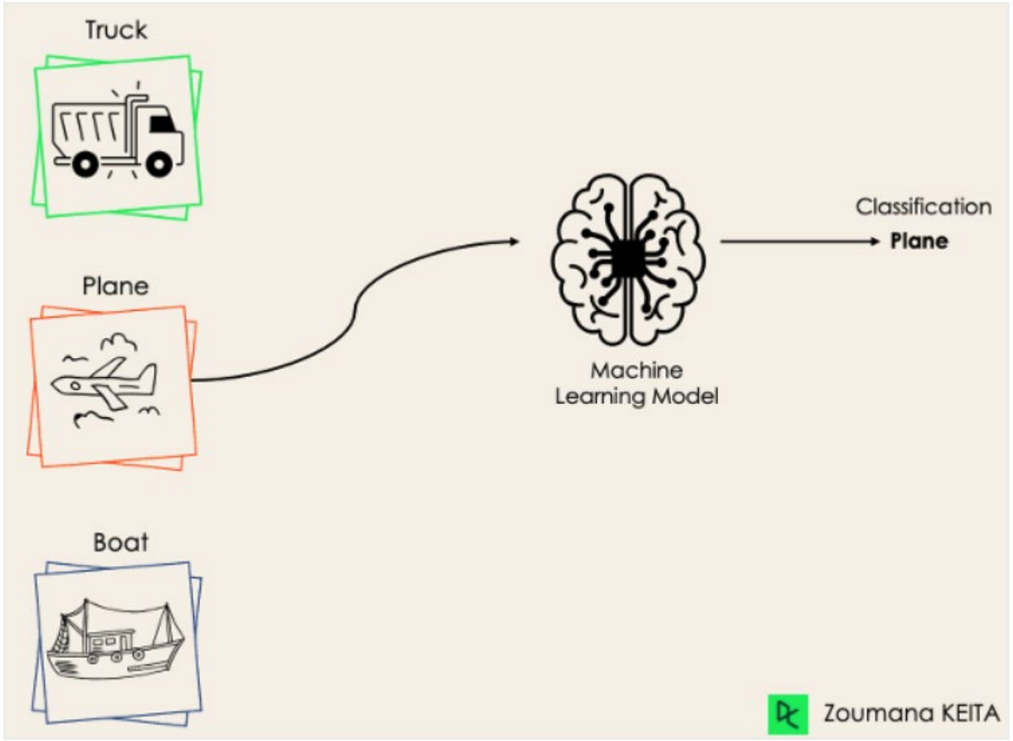
Tipos de clasificación

CLASIFICACIÓN MULTICLASE

La clasificación multiclase, por otro lado, tiene **a lo menos dos etiquetas de clase mutuamente excluyentes**, donde el objetivo es predecir a qué clase pertenece un ejemplo de entrada dado.

En el siguiente caso, el modelo clasificó correctamente la imagen como un avión.

La mayoría de los algoritmos de clasificación binaria también se pueden utilizar para la clasificación multiclase.



FUENTE: https://www.datacamp.com/blog/classification-machine-learning

El problema de clasificación

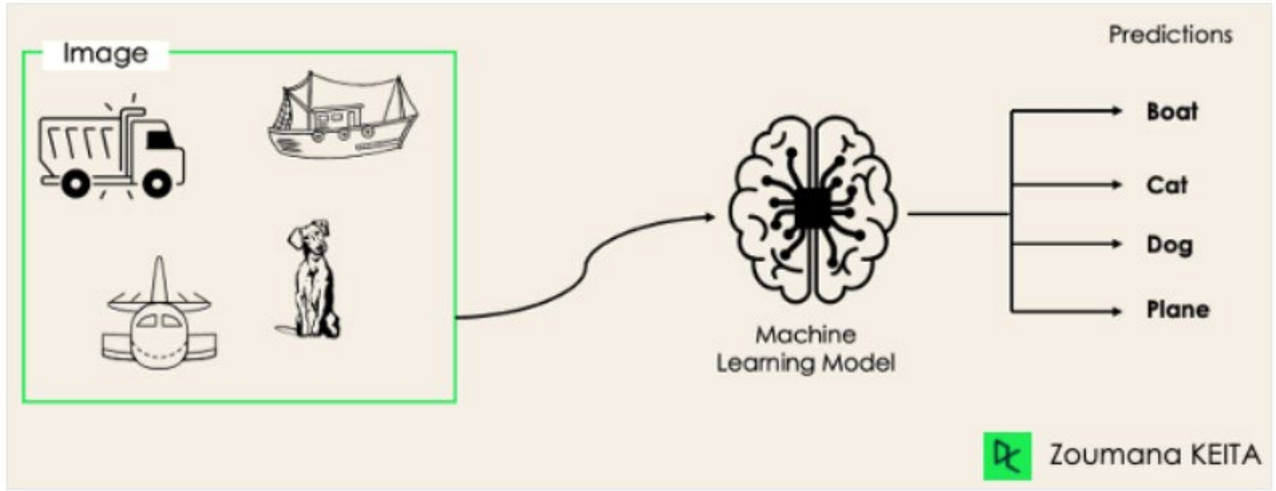
Tipos de clasificación

CLASIFICACIÓN DE ETIQUETAS MÚLTIPLES

En las tareas de clasificación de etiquetas múltiples, intentamos **predecir 1 o más clases para cada ejemplo de entrada**.

En este caso, no hay exclusión mutua porque el ejemplo de entrada puede tener más de una etiqueta.

Este escenario se puede observar en diferentes dominios, como el etiquetado automático en el procesamiento del lenguaje natural, donde un texto determinado puede contener varios temas. De manera similar a la visión por computadora, una imagen puede contener múltiples objetos, como se ilustra a continuación: el modelo predijo que la imagen contiene: un avión, un bote, un camión y un perro.



FUENTE: https://www.datacamp.com/blog/classification-machine-learning

DuocUC

<> ESCUELA DE INFORMÁTICA Y TELECOMUNICACIONES

Algoritmo 1: Regresión logística

Regresión logística

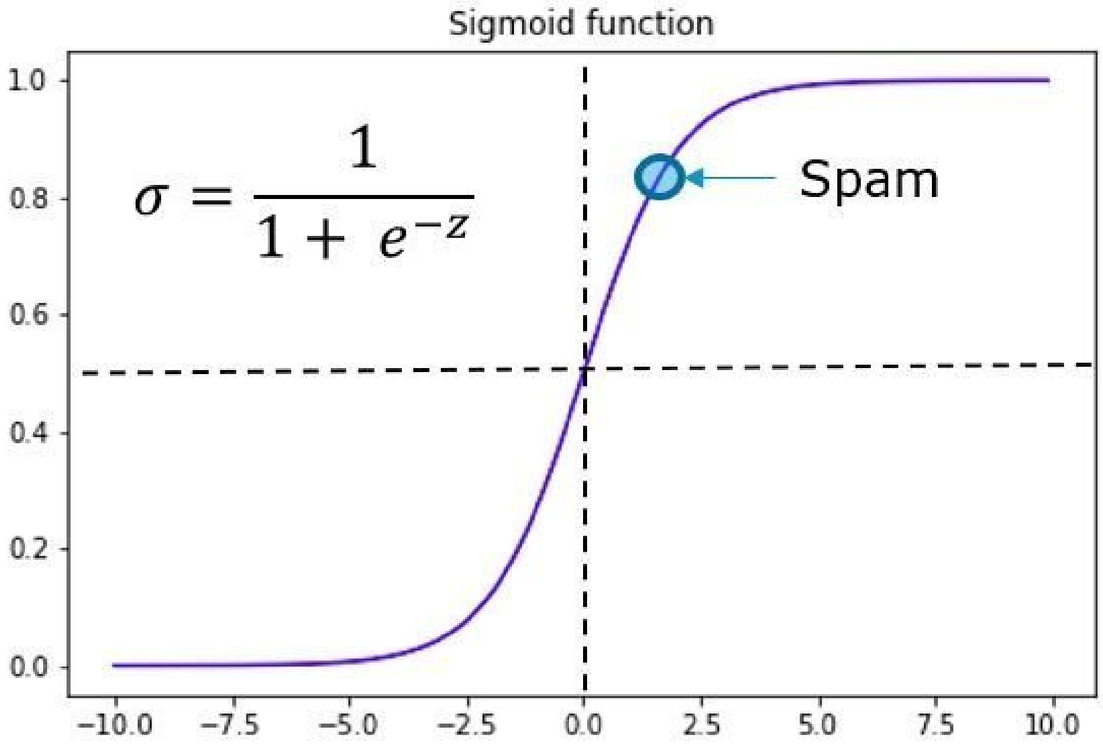
La regresión logística es un **clasificador probabilístico** que maneja problemas de clasificación binaria.

Dada una muestra (x, y), genera una probabilidad “p” de que la muestra pertenezca a la clase positiva:

$$p = P(y = 1|\mathbf{x})$$

Si esta probabilidad es superior a algún valor de umbral (normalmente elegido como 0,5), la muestra se clasifica como 1; de lo contrario, se clasifica como 0.

Regresión logística



La regresión logística **es uno de los algoritmos de aprendizaje automático más comunes**.

Se puede usar para predecir la probabilidad de que ocurra un evento, como si un correo electrónico entrante es correo no deseado o no, o si un tumor es maligno o no, en función de un conjunto de datos etiquetados determinado.

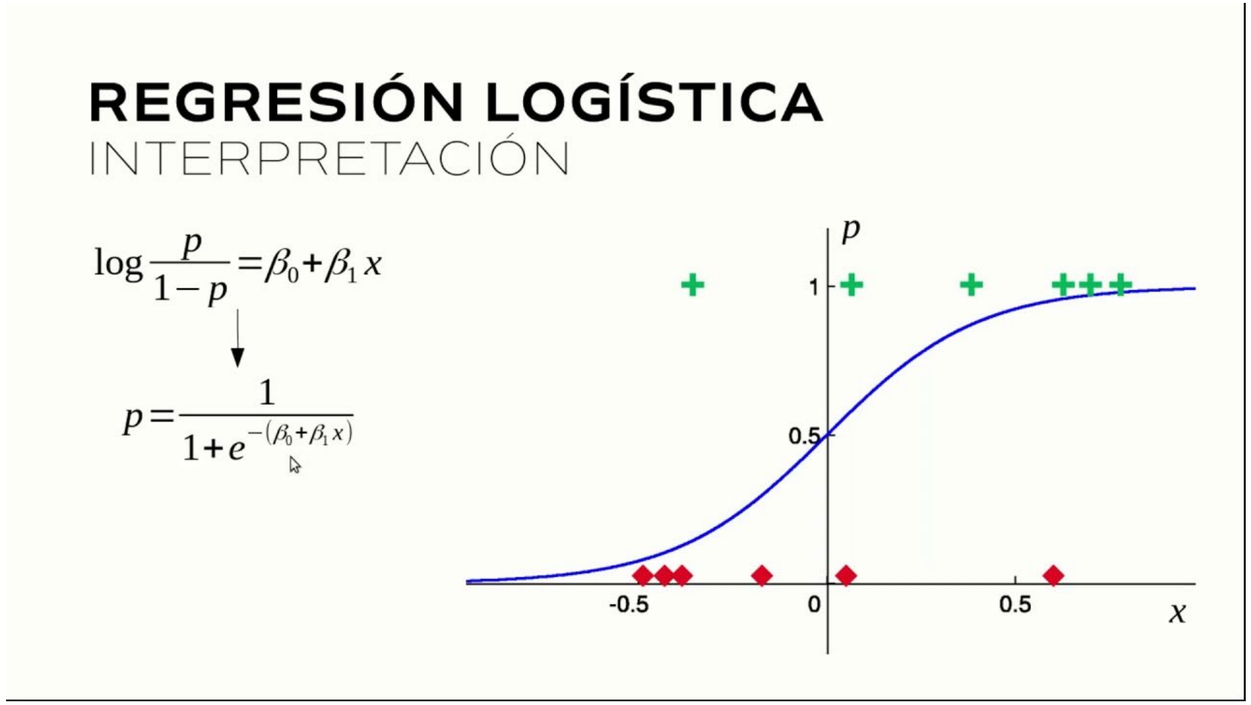
Debido a su simplicidad, la regresión logística **a menudo se usa como línea de base contra la cual se evalúan otros modelos más complejos**.

FUENTE: https://towardsdatascience.com/mastering-logistic-regression-3e502686f0ae

Regresión logística

El modelo tiene la palabra "logística" en su nombre, ya que **utiliza la función logística (sigmoide) para convertir una combinación lineal de las características de entrada en probabilidades**.

También tiene **la palabra "regresión" en su nombre, ya que su salida es un valor continuo entre 0 y 1**, aunque **normalmente se usa como un clasificador binario** al elegir un valor de umbral (generalmente 0,5) y clasificar las entradas con probabilidad mayor que el umbral como la clase positiva, y aquellos por debajo del umbral como la clase negativa.



Los **clasificadores probabilísticos generan estimaciones de probabilidad para las clases** y luego asignan una etiqueta a la muestra dada en función de estas probabilidades (generalmente, la etiqueta de la clase con la probabilidad más alta).

FUENTE: https://towardsdatascience.com/mastering-logistic-regression-3e502686f0ae

Regresión logística

¿Cómo estima el modelo la probabilidad “p”?

La suposición básica en la regresión logística es que **las probabilidades logarítmicas del evento de que la muestra pertenezca a la clase positiva es una combinación lineal de sus características**.

Log-odds (también llamado logit) **es el logaritmo de la razón de posibilidades**, que es la relación entre la probabilidad de que la muestra pertenezca a la clase positiva y la probabilidad de que pertenezca a la clase negativa:

$$\text{logit}(p) = \log \frac{p}{1-p}$$

The log-odds (logit) function

FUENTE: https://towardsdatascience.com/mastering-logistic-regression-3e502686f0ae

Regresión logística

En la regresión logística, asumimos que el logaritmo de las probabilidades es una combinación lineal de las características, ver la fórmula.

Donde w = (w_0, …, w_m) son los **parámetros** (o pesos) del modelo. El parámetro w_0 a menudo se denomina **intersección** (o sesgo).

Los puntos para los que p = 0,5 (es decir, el logaritmo de probabilidades es igual a 0) definen el hiperplano de separación entre las dos clases, cuya ecuación es:

$$\log \frac{p}{1-p} = w_0 + w_1 x_1 + \ldots + w_m x_m = \mathbf{w}^T \mathbf{x}$$

$$\mathbf{w}^T \mathbf{x} = 0$$

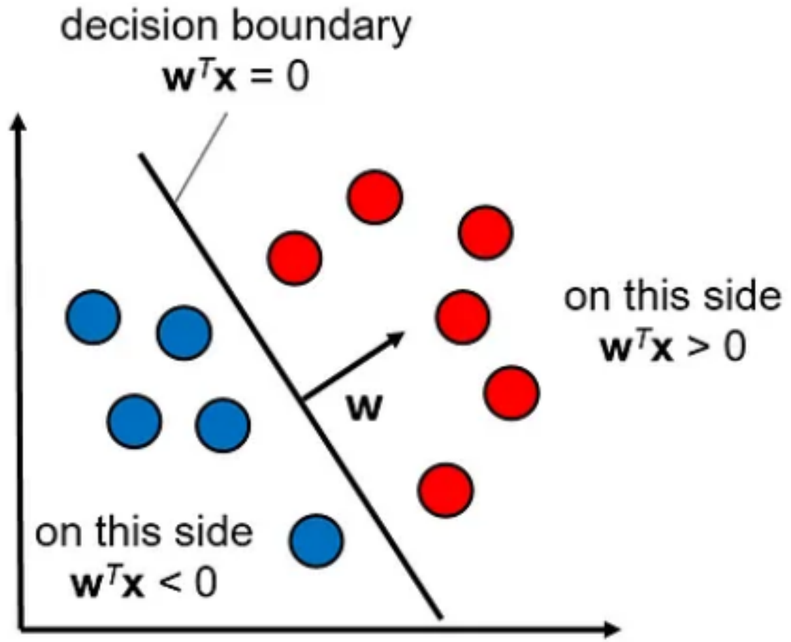
The equation of the separating hyperplane

Regresión logística

El vector de peso w es ortogonal (perpendicular) a este hiperplano.

Cada ejemplo por encima del hiperplano ($w^t x > 0$) se clasifica como un ejemplo positivo, mientras que cada ejemplo por debajo del hiperplano ($w^t x < 0$) se clasifica como un ejemplo negativo.

Esto convierte a la regresión logística en un clasificador lineal, ya que asume que el límite entre las clases es una superficie lineal.



FUENTE: https://towardsdatascience.com/mastering-logistic-regression-3e502686f0ae

Regresión logística

Podemos encontrar una correlación directa entre p y los parámetros w, "exponenciando" ambos lados de la ecuación de log-odds:

$$\frac{p}{1-p} = e^{\mathbf{w}^T\mathbf{x}}$$

$$p = (1-p)e^{\mathbf{w}^T\mathbf{x}}$$

$$p(1+e^{\mathbf{w}^T\mathbf{x}}) = e^{\mathbf{w}^T\mathbf{x}}$$

$$p = \frac{e^{\mathbf{w}^T\mathbf{x}}}{(1+e^{\mathbf{w}^T\mathbf{x}})} = \frac{1}{1+e^{-\mathbf{w}^T\mathbf{x}}} = \sigma(\mathbf{w}^T\mathbf{x})$$

donde σ es la función sigmoidea (también conocida como función logística):

$$\sigma(z) = \frac{1}{1+e^{-z}}$$

FUENTE: https://towardsdatascience.com/mastering-logistic-regression-3e502686f0ae

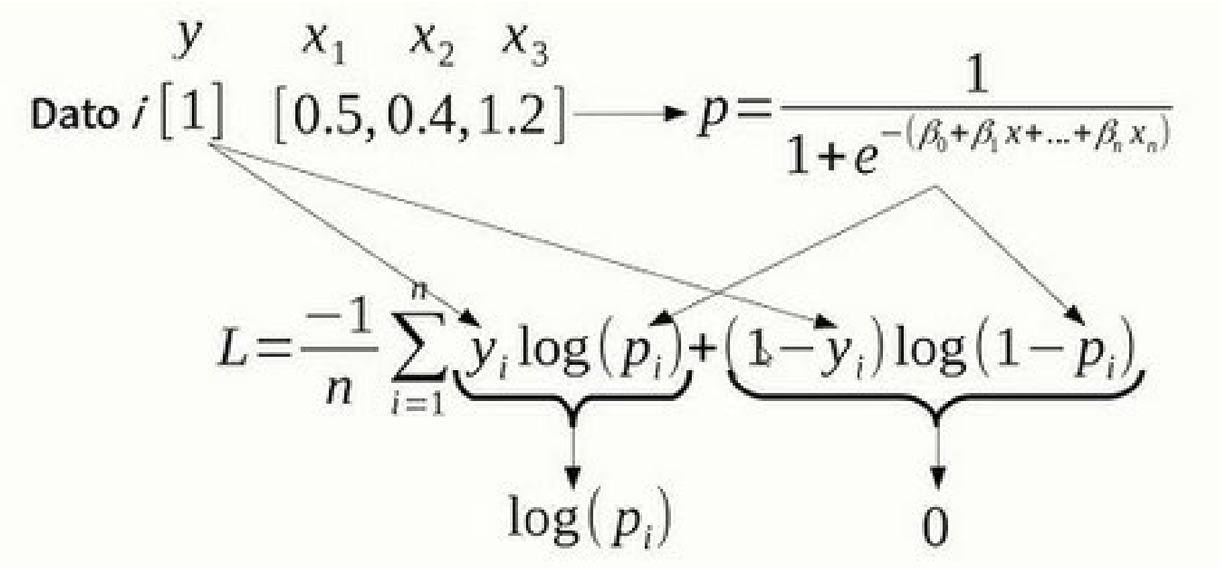
Regresión logística

El modelo se entrena maximizando la **verosimilitud**, o de forma equivalente, minimizando la **pérdida logarítmica (log-loss)**:

$$\mathcal{L}(\boldsymbol{w}) = -\sum_{i=1}^{n} y_i \log(\tilde{p}_i) + (1 - y_i) \log(1 - \tilde{p}_i)]$$

Esta función es **convexa**, lo que garantiza un mínimo global.

EJEMPLO



<> ESCUELA DE **INFORMÁTICA Y TELECOMUNICACIONES**

DuocUC®

CERCANÍA. LIDERAZGO. FUTURO.

7 AÑOS ACREDITADO

Comisión Nacional de Acreditación CNA-Chile

NIVEL DE EXCELENCIA

HASTA OCTUBRE 2031

Docencia de pregrado / Gestión institucional / Aseguramiento interno de la calidad / Vinculación con el Medio / Investigación, creación y/o innovación