

DuocUC

Métricas de clasificación

Machine Learning TLY1101

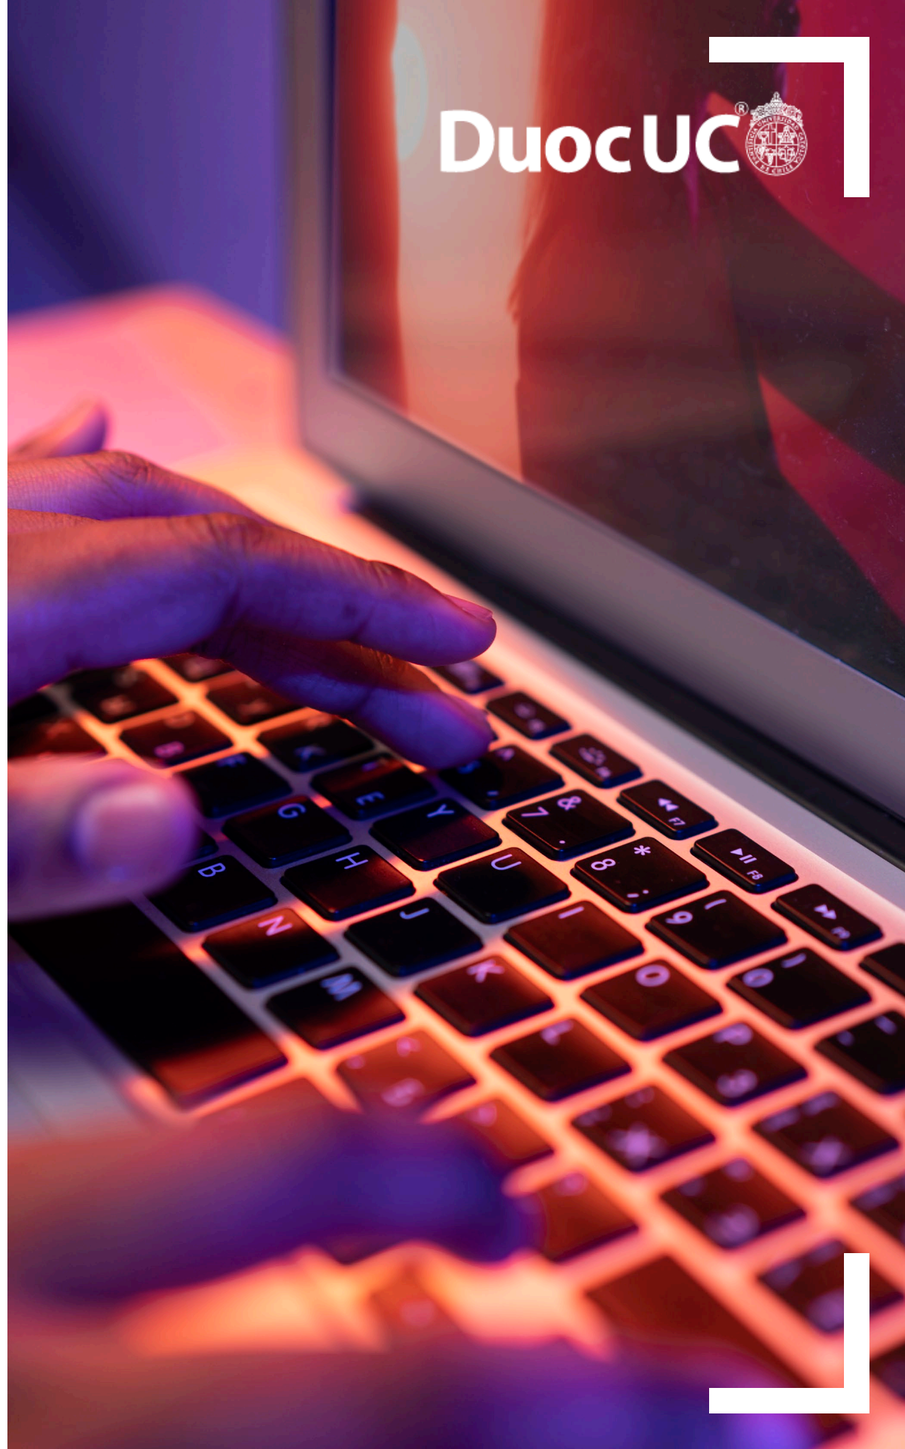
Contenido

01

Métricas de clasificación

02

Algoritmo 2: Support Vector Machine (SVM)



DuocUC

<> ESCUELA DE INFORMÁTICA Y TELECOMUNICACIONES

Métricas de clasificación

Métricas de clasificación

- Tradicionalmente, las clases son representadas con números 0 y 1 o -1 y 1.
- Estas clases tendrán la nominación de ***clase negativa*** y ***clase positiva***. Se debe decidir cual es la clase negativa y cual es la clase positiva. NO asocie el -1 a negativa necesariamente.
- Usaremos algo llamado: **Matriz de confusión** para crear nuestras métricas de rendimiento.
- Mediante un ejemplo médico veremos su aplicación.

Métricas de clasificación

- Suponer que se tiene una máquina que, dado datos clínicos de un paciente clasifica al paciente entre enfermo y sano.

- Sano será nuestra clase positiva y enfermo será nuestra clase negativa.

- Entonces, podemos tener 4 escenarios:

1) La máquina dice sano y el paciente está realmente sano **(acierto).**

2) La máquina dice sano y el paciente está realmente enfermo **(error).**

3) La máquina dice enfermo y el paciente está realmente sano **(error).**

4) La máquina dice enfermo y el paciente está realmente enfermo **(acierto).**

Métricas de clasificación

Llamaremos verdadero positivo (True Positive) y verdadero negativo (True Negative) cuando el clasificador da un pronóstico correcto.

Llamaremos falso negativo (False Negative) y falso positivo (False Positive) cuando el clasificador se equivoca.

P’ = cantidad de ejemplos que dice sano.

N’ = cantidad de ejemplos que dice enfermo.

P = cantidad de ejemplos que realmente son sano.

N = cantidad de ejemplos que realmente son enfermo.

	Sano	Enfermo	Total
Dice Sano	True Positive	False Positive	P'
Dice Enfermo	False Negative	True Negative	N'
Total	P	N	

Métricas de clasificación

Las **métricas más comunes** que se pueden calcular directamente de la matriz de confusión son:

$$Accuracy = \frac{TP + TN}{P + N}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Sensitivity = \frac{TP}{TP + FN}$$

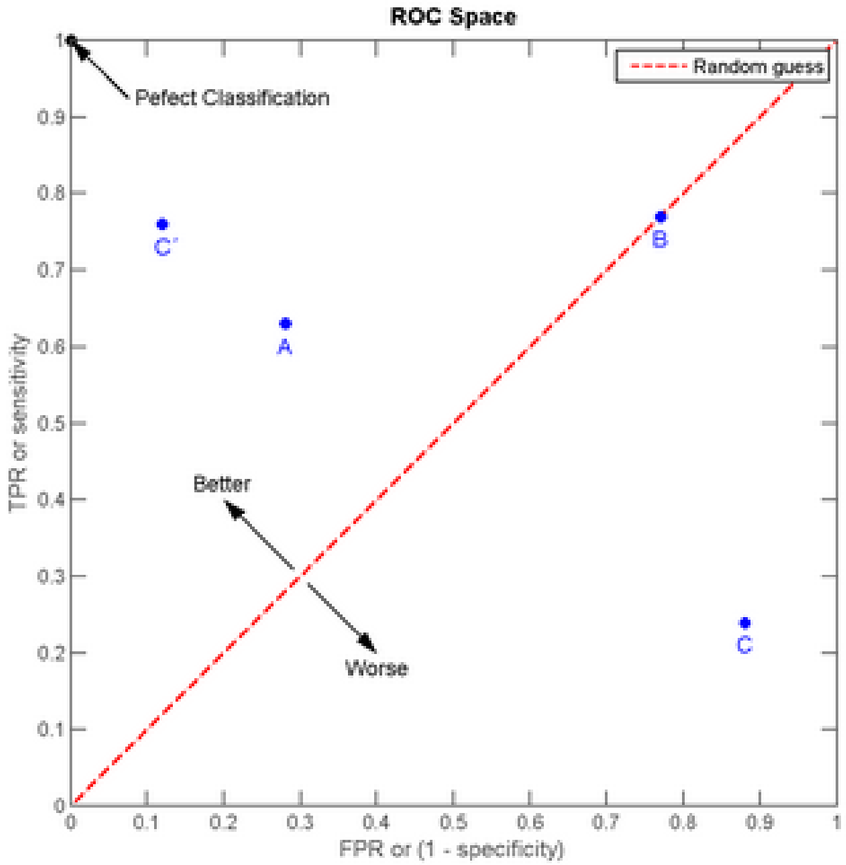
$$F - measure = \frac{2}{\frac{1}{Precision} + \frac{1}{Sensitivity}}$$

donde: TP = True Positive, TN = True Negative
FP = False Positive, FN = False Negative

¿Le puedo creer al algoritmo cuando dice sano?
¿Qué métrica me sirve para eso?

Métricas de clasificación

Existe algo llamado **espacio ROC**, el cual nos sirve para comparar algoritmos.



B es un clasificador aleatorio (tirar una moneda).

C es el peor.

C' es el mejor.

El **ROC space** sirve para comparar varios clasificadores y como se puede observar, el que está más cerca del punto (0,1), es decir, la esquina superior izquierda, es el mejor.

Existe una forma más completa de ver el rendimiento de varios algoritmos, lo cual se realiza variando un valor umbral que permite crear varios puntos en el espacio ROC para un mismo algoritmo.

No vamos a ver en detalle cómo se calcula, pero si revisaremos el concepto y como se calcula en scikit-learn.

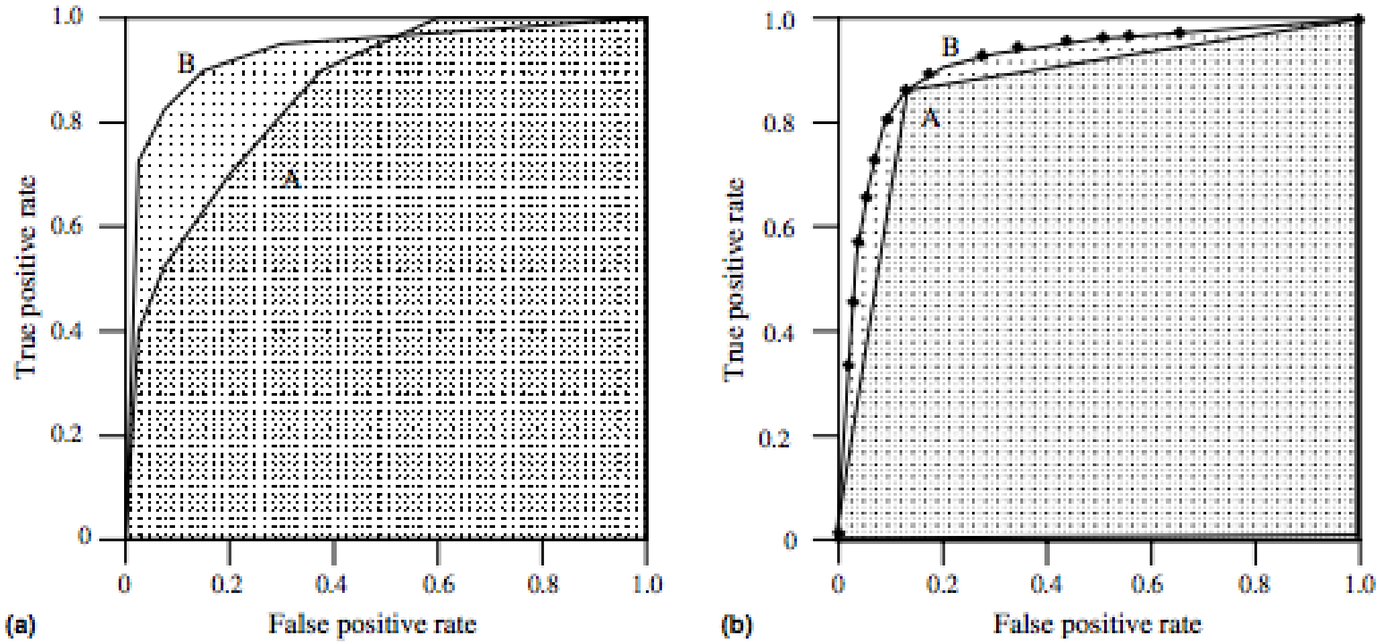
Métricas de clasificación

- El área bajo la curva (area under curve - AUC) es un número que indica el rendimiento “promedio” de un clasificador bajo distintos valores de umbral.
- Es una manera de comparar clasificadores de manera general.
- Cada clasificador entrega una curva en el espacio ROC, entonces, el AUC es el área bajo la curva ROC que genera el clasificador.

En la imagen (a), el clasificador B es mejor que el A.

En la imagen (b), el clasificador B es mejor, pero en un punto del umbral, ambos tienen el mismo rendimiento.

En scikit-learn:
sklearn.metrics.roc_auc_score



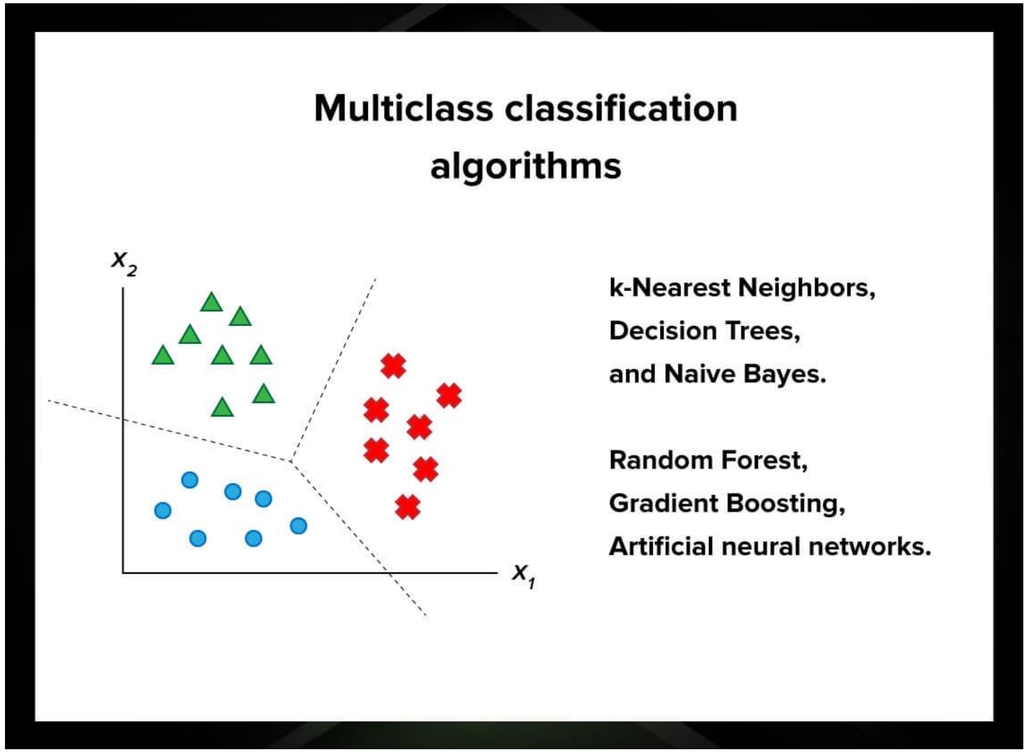
Métricas de clasificación:

Caso multiclase

Mientras que los clasificadores binarios distinguen entre dos clases, **los clasificadores multiclase (también llamados clasificadores multinomiales) pueden distinguir entre más de dos clases**.

Algunos algoritmos (como Random Forest y Bayes ingenuo) son capaces de manejar múltiples clases de manera nativa.

Otros (como los SVM o regresión logística) son estrictamente clasificadores binarios. **Sin embargo, hay varias estrategias que se pueden utilizar para llevar a cabo una clasificación multiclase con múltiples clasificadores binarios.**



FUENTE: Aprende Machine Learning con Scikit-Learn, Keras y TensorFlow, A.Géron

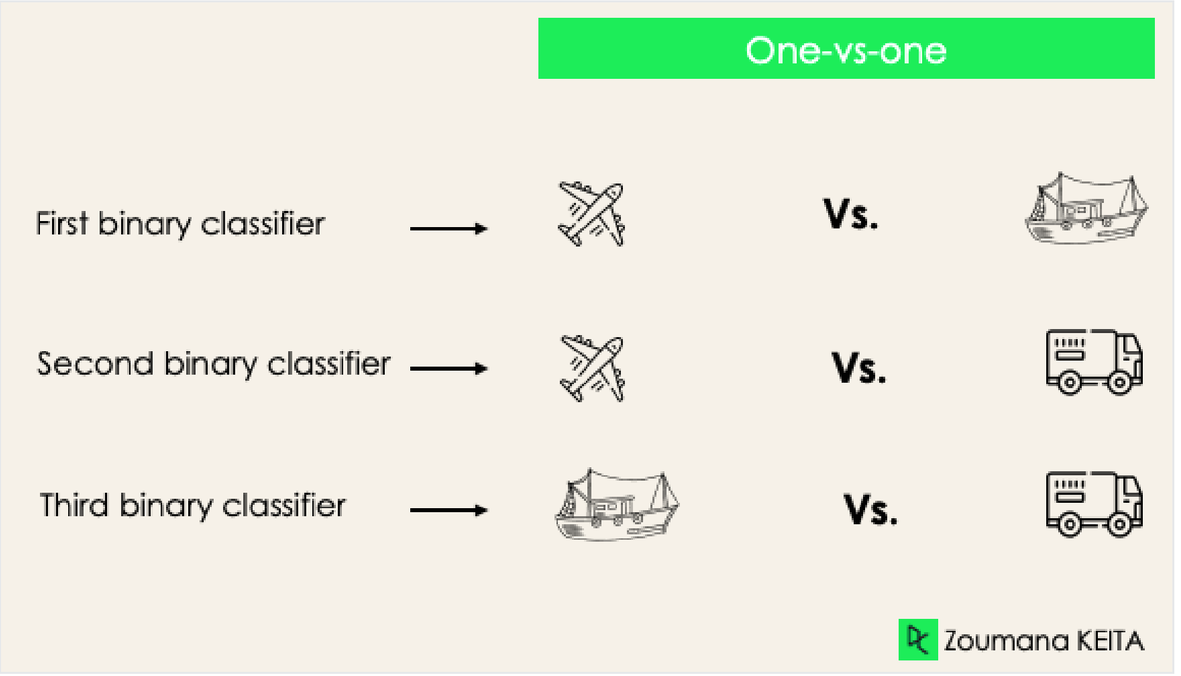
Métricas de clasificación:

Caso multiclase

ONE VERSUS ONE

Esta estrategia entrena tantos clasificadores como pares de etiquetas hay.

Si tenemos una clasificación de tres clases, tendremos tres pares de etiquetas, por lo tanto, tres clasificadores, como se muestra en la figura.



FUENTE: https://www.datacamp.com/blog/classification-machine-learning

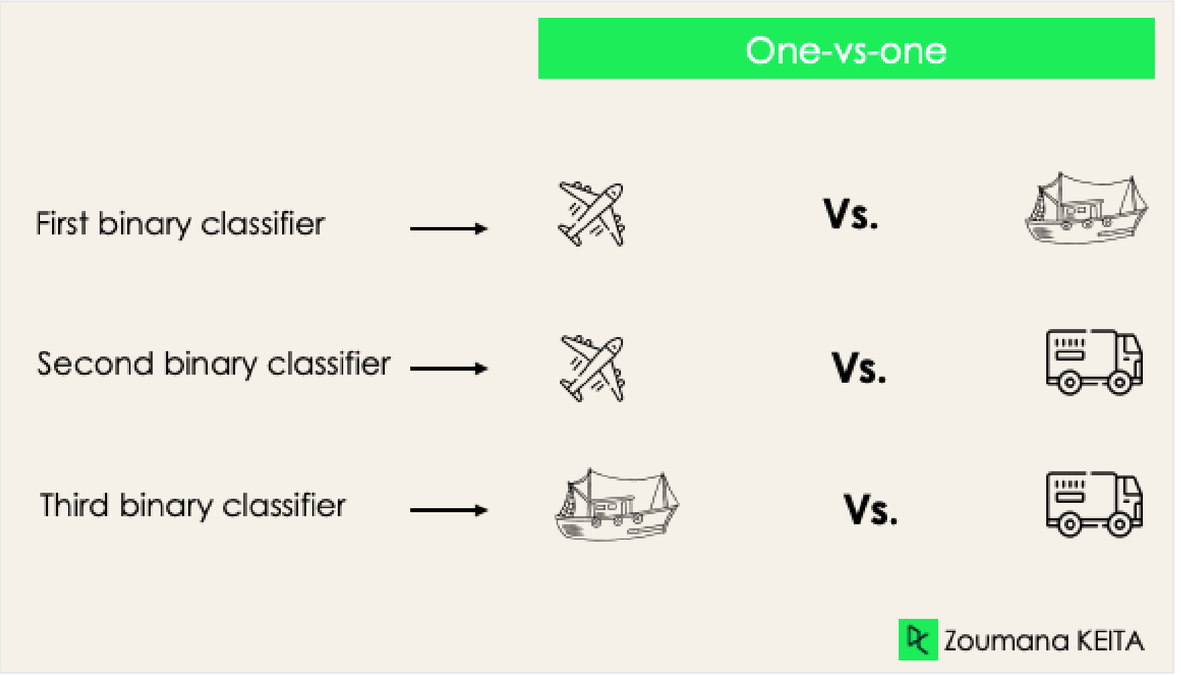
Métricas de clasificación:
Caso multiclase

ONE VERSUS ONE

En general, para N etiquetas, tendremos Nx(N-1)/2 clasificadores.

Cada clasificador se entrena en un solo conjunto de datos binarios, y la clase final se predice mediante un voto mayoritario entre todos los clasificadores.

La gran ventaja es que cada clasificador solo necesita entrenarse en la parte del conjunto de entrenamiento para las dos clases que debe distinguir.



FUENTE: https://www.datacamp.com/blog/classification-machine-learning

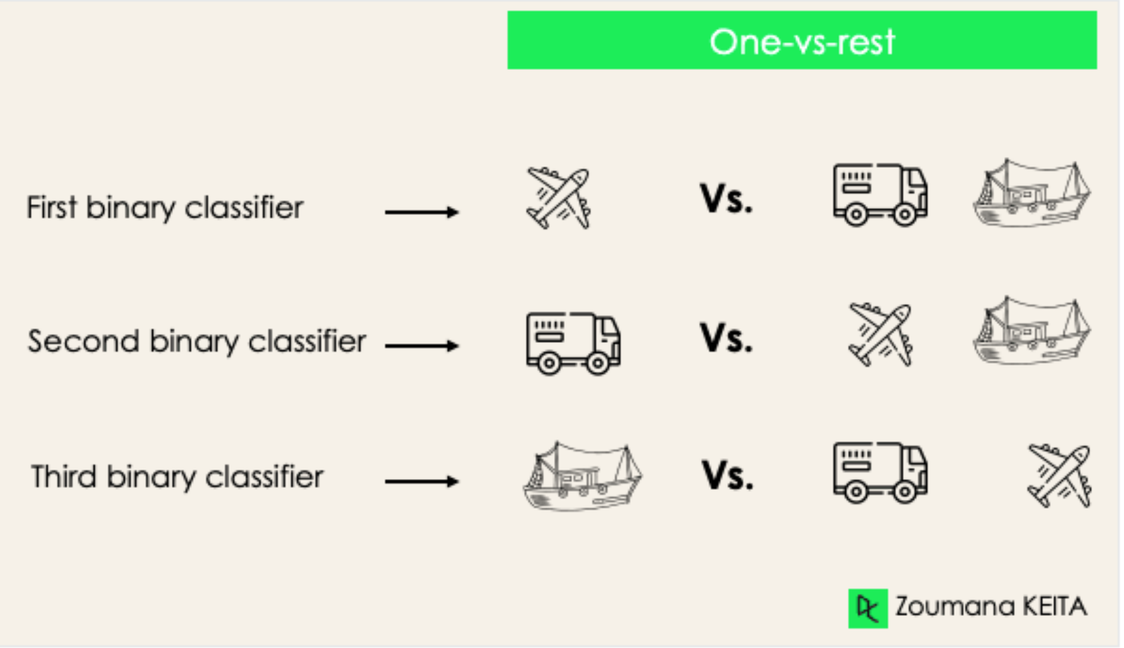
Métricas de clasificación:
Caso multiclase

ONE VERSUS REST

En esta estrategia, comenzamos por considerar **cada etiqueta como una etiqueta independiente y consideramos el resto combinado como una sola etiqueta**.

Con tres clases, tendremos tres clasificadores. En general, para N etiquetas, tendremos N clasificadores binarios.

Una forma de crear un sistema que pueda clasificar las imágenes de dígitos en diez clases (de 0 a 9) es entrenar diez clasificadores binarios, uno para cada dígito.



FUENTE: https://www.datacamp.com/blog/classification-machine-learning

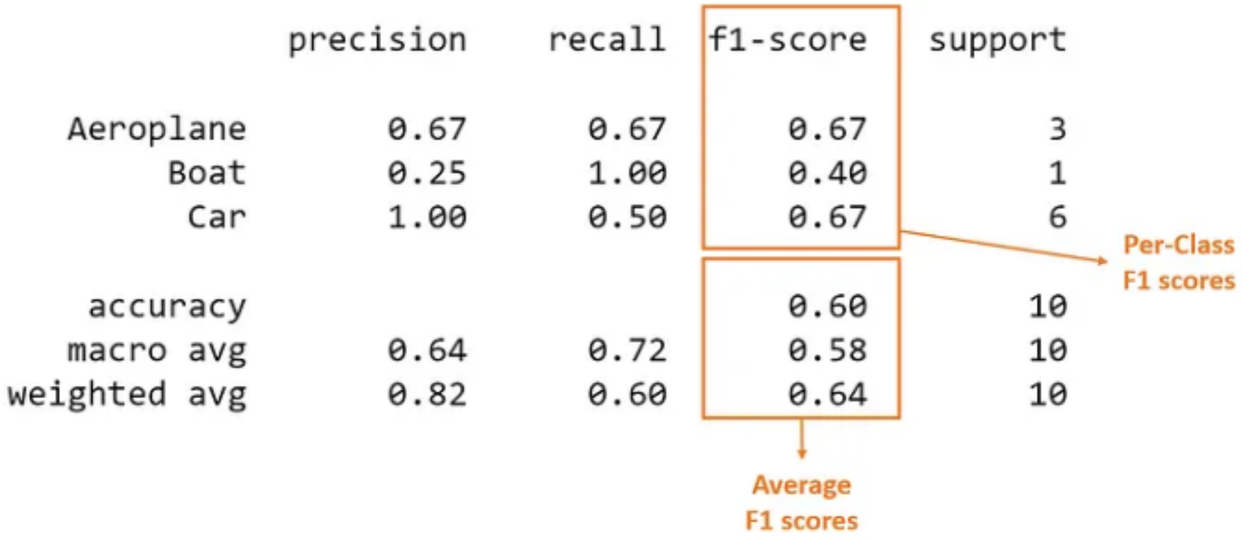
Métricas de clasificación:

Caso multiclase

Al ejecutar reporte de métricas de clasificación, podemos observar que :

Las columnas (en naranja) con los puntajes por clase (es decir, el puntaje de cada clase) y los puntajes promedio son lo que explicaremos.

Podemos ver en lo anterior que el conjunto de datos está desequilibrado (solo una de cada diez instancias del conjunto de prueba es 'Bote'). Por lo tanto, la proporción de coincidencias correctas (también conocida como precisión) sería ineficaz para evaluar el rendimiento del modelo.



Reporte de métricas obtenido con Scikit Learn

FUENTE : https://towardsdatascience.com/micro-macro-weighted-averages-of-f1-score-clearly-explained-b603420b292f

Métricas de clasificación:

Caso multiclase

Vemos la matriz de confusión para una comprensión gráfica de las predicciones del modelo.

La matriz de confusión nos permite calcular los valores críticos de verdadero positivo (TP), falso positivo (FP) y falso negativo (FN).

		Predicted		
		Airplane	Boat	Car
Actual	Airplane	2	1	0
	Boat	0	1	0
	Car	1	2	3

Label	True Positive (TP)	False Positive (FP)	False Negative (FN)
Airplane	2	1	1
Boat	1	3	0
Car	3	0	3

DuocUC®

<> ESCUELA DE **INFORMÁTICA Y TELECOMUNICACIONES**

SVM

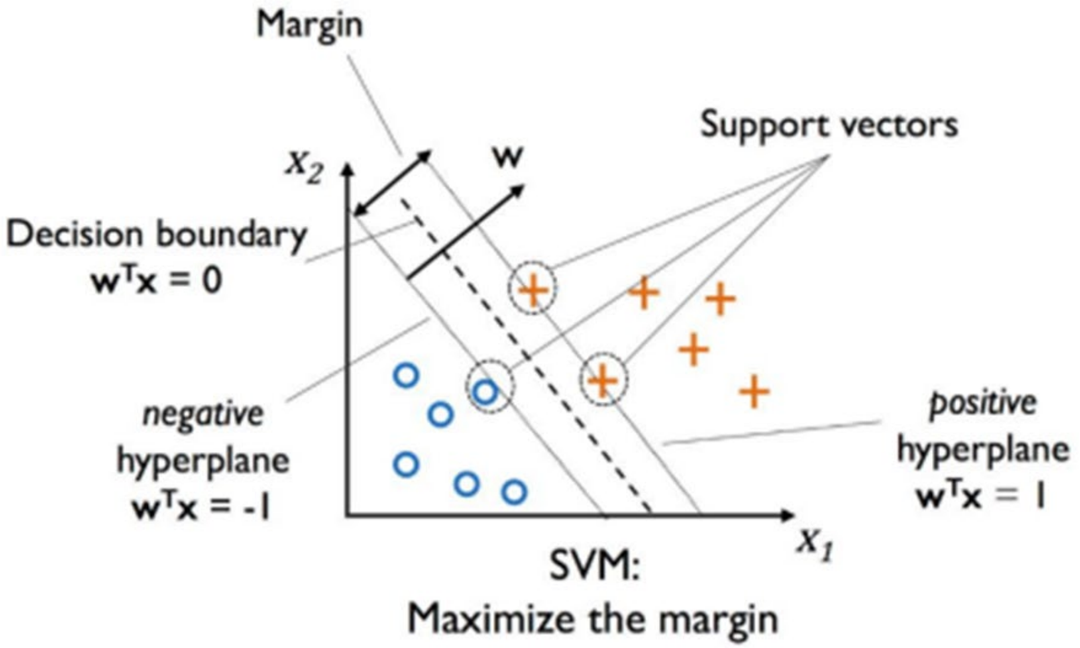
SVM

Las **máquinas de soporte vectorial** (Support Vector Machine - SVM) tienen su origen en los años 90 por Vapnik y sus colaboradores.

El objetivo de optimización es maximizar el "**margen**".

El margen se define como la distancia entre el hiperplano de separación y los ejemplos de entrenamiento cercanos a este hiperplano, los cuales son llamados **vectores de soporte**.

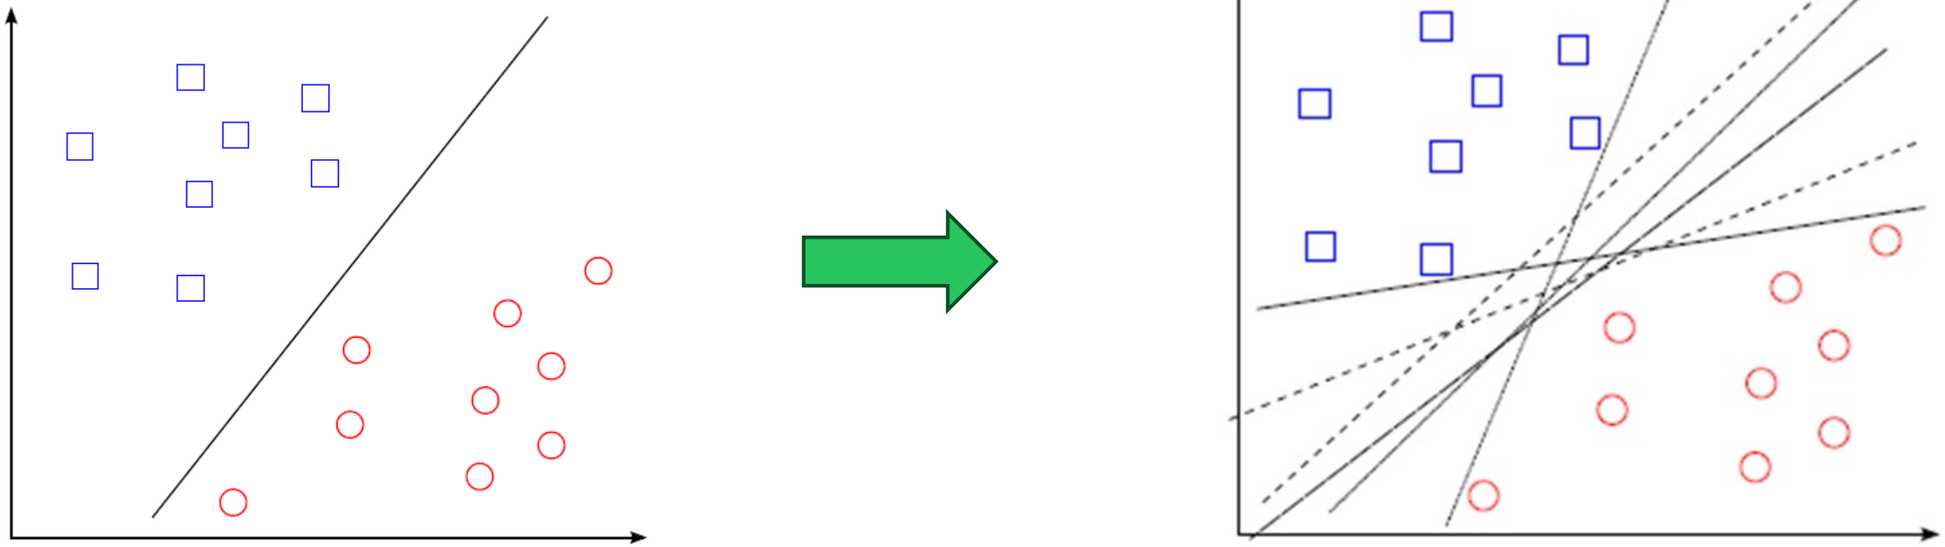
Se puede usar en regresión y en clasificación.



SVM

SVM para ejemplos linealmente separables.

A partir de un conjunto de ejemplos separables en dos clases, podemos encontrar varios hiperplanos de separación, de entre los infinitos posibles.

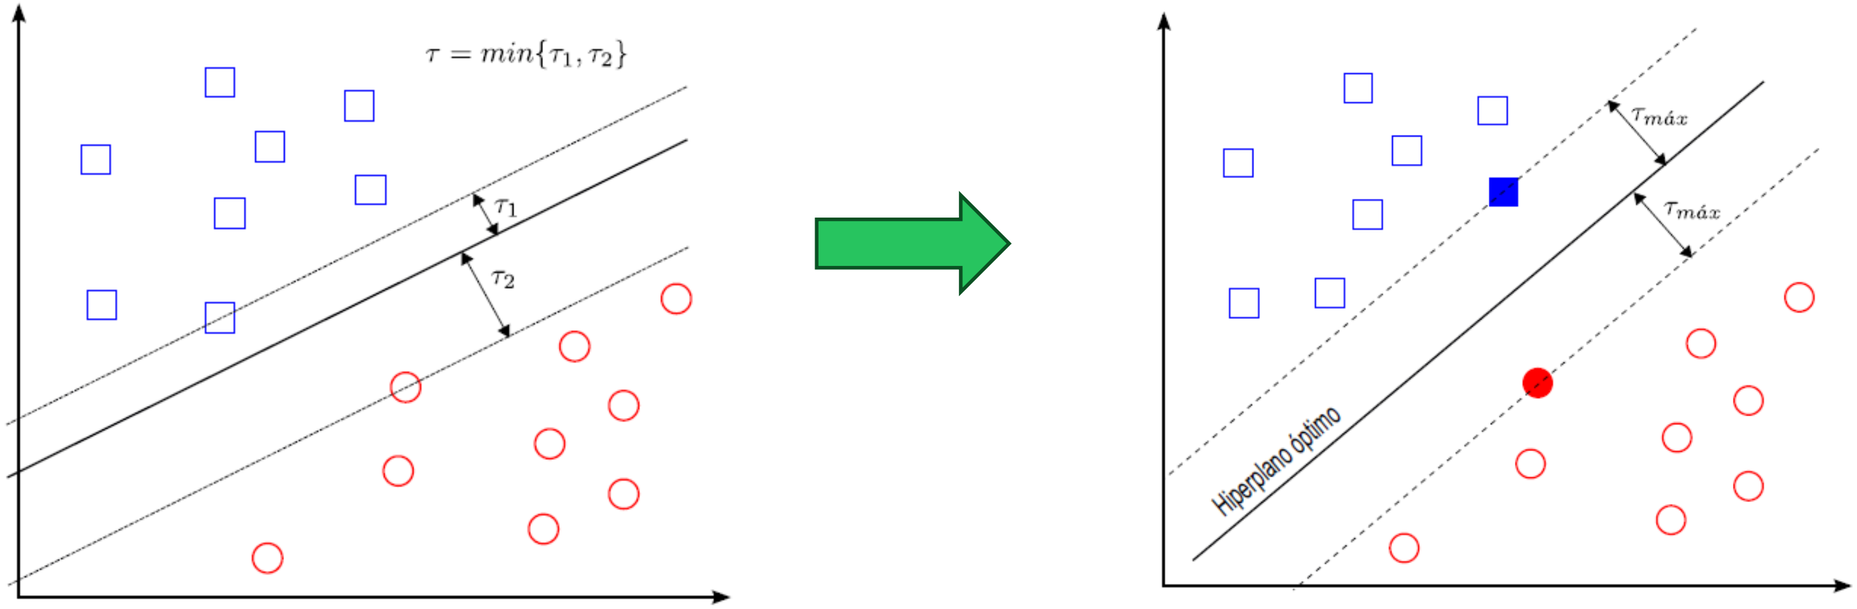


FUENTE : Tutorial sobre SVM, Enrique J. Carmona Suaréz, UNED, España, 2016

SVM

SVM para ejemplos linealmente separables.

Se define **margen (letra *Teta* en el dibujo) de un hiperplano**, como la mínima distancia entre dicho hiperplano y el ejemplo más cercano de cualquiera de las dos clases. Este hiperplano **será óptimo si su margen es de tamaño máximo**.



FUENTE : Tutorial sobre SVM, Enrique J. Carmona Suaréz, UNED, España, 2016

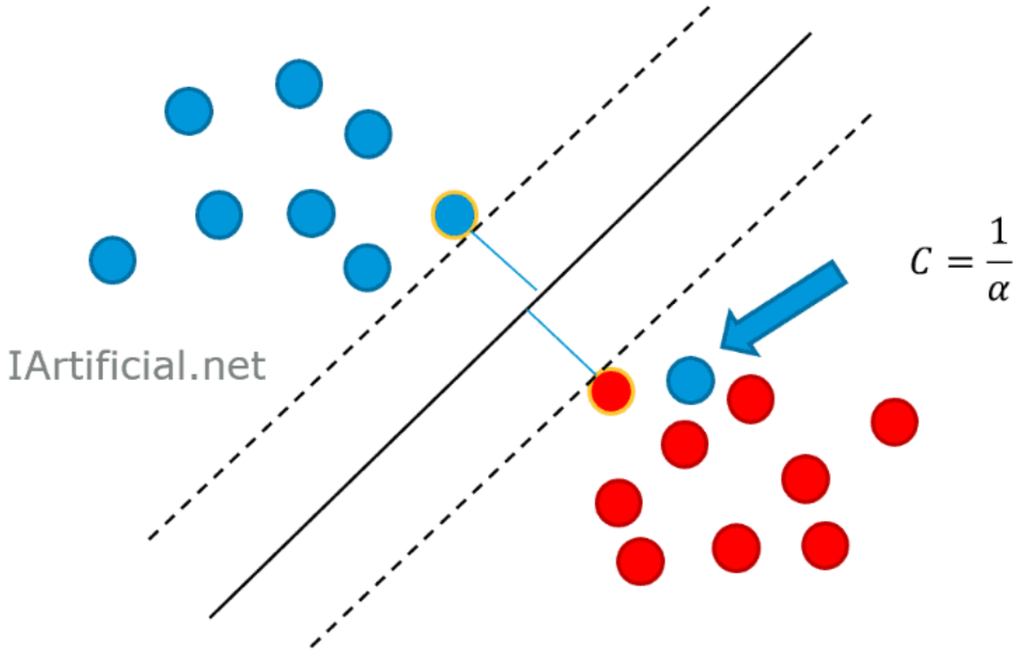
SVM

SVM para ejemplos NO linealmente separables, (regularización).

Es bastante frecuente que los datos tengan ruido, que no estén etiquetados perfectamente, o que el problema sea tan difícil, que para unos pocos puntos, sea muy complicado clasificarlos correctamente.

Para estos casos, preferimos que SVM generalice bien para la mayoría de los casos, aunque algunos pocos casos del conjunto de entrenamiento no estén perfectamente clasificados.

Para controlar la cantidad de regularización, podemos usar el hiper-parámetro *C que cuantifica el número de datos mal clasificados.*



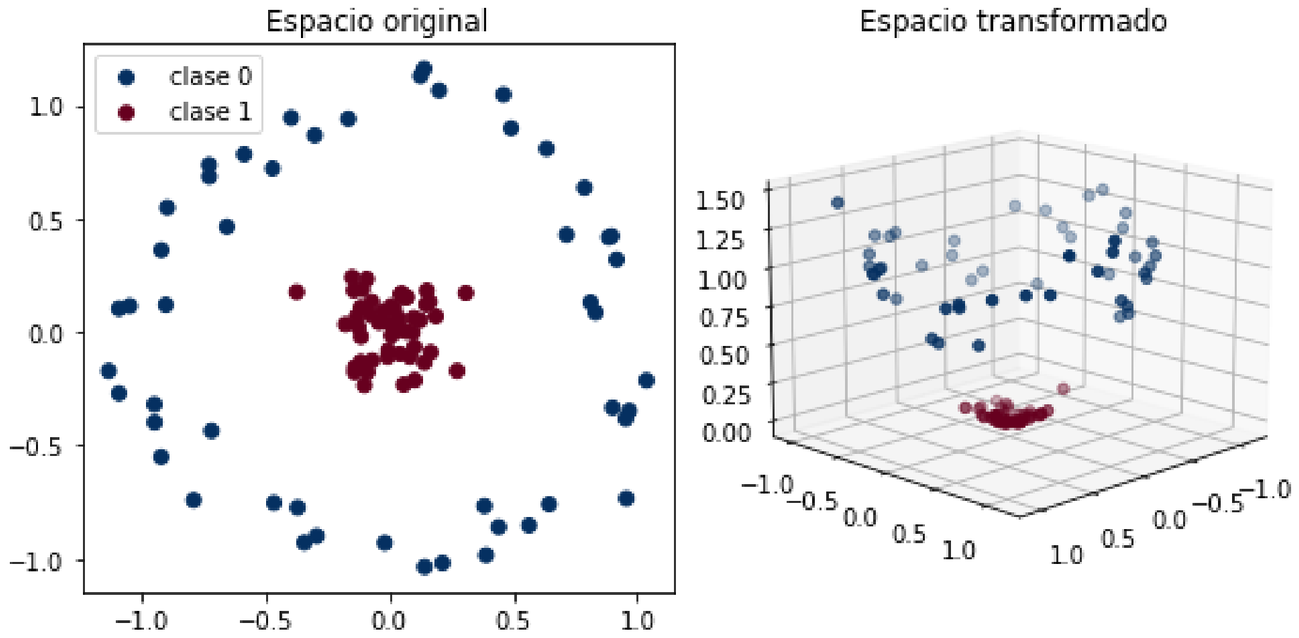
El parámetro C controla el compromiso entre maximizar el margen y minimizar el error de entrenamiento. Un valor de C más alto enfatiza la importancia de clasificar correctamente cada ejemplo de entrenamiento, lo que puede conducir a un sobreajuste. Por el contrario, un valor C más bajo permite un margen más amplio, pero puede dar lugar a una clasificación errónea. Rango de valor C: 0,001 a 1000

SVM

SVM, para ejemplos no separables linealmente (Kernel-Trick).

Hay veces en las que no hay forma de encontrar una hiperplano que permita separar dos clases. En estos casos decimos que las clases no son linealmente separables.

Para resolver este problema podemos usar el **truco del kernel**. Este **consiste en crear un espacio de dimensión mayor** en la que podamos encontrar un hiperplano para separar las clases.



La figura izquierda muestra los datos en su espacio original (dos dimensiones). Claramente no es posible separarlos con un hiperplano.

La figura derecha muestra los datos en el espacio transformado (tres dimensiones). En este espacio si se pueden separar por un hiperplano.

FUENTE : https://www.iartificial.net/maquinas-de-vectores-de-soporte-svm/

<> ESCUELA DE **INFORMÁTICA Y TELECOMUNICACIONES**

DuocUC®

CERCANÍA. LIDERAZGO. FUTURO.

7 AÑOS ACREDITADO

Comisión Nacional de Acreditación CNA-Chile

NIVEL DE EXCELENCIA

HASTA OCTUBRE 2031

Docencia de pregrado / Gestión institucional / Aseguramiento interno de la calidad / Vinculación con el Medio / Investigación, creación y/o innovación